第十九届全国大学生信息安全竞赛（作品赛）
暨第三届“长城杯”网数智安全大赛（作品赛）
作品报告

□命题赛道　　☑自由赛道

作品名称：PrivLLM：隐私保护的边云协同大模型推理平台

电子邮箱：yinhaoran0808@outlook.com

提交日期：2026.07.05

填写说明

1. 所有参赛项目必须为一个基本完整的设计。作品报告书旨在能够清晰准确地阐述（或图示）该参赛队的参赛项目（或方案）。

2. 作品报告采用A4纸撰写。除标题外，所有内容必需为宋体、小四号字、1.5倍行距。

3. 作品报告中各项目说明文字部分仅供参考，作品报告书撰写完毕后，请删除所有说明文字。(本页不删除)

4. 作品报告模板里已经列的内容仅供参考，作者可以在此基础上增加内容或对文档结构进行微调。

5. 为保证网评的公平、公正，作品报告中应避免出现作者所在学校、院系和指导教师等泄露身份的信息。

目　录

摘要 1

第一章 作品概述 4

1.1 背景分析 4

1.2 相关工作 5

1.3 作品特色 7

1.4 应用前景分析 8

1.4.1 应用场景 8

1.4.2 市场价值 9

第二章 作品设计与实现 10

2.1 方案总体设计 10

2.2 大模型推理与 Transformer 架构 11

2.3 关键技术 12

2.3.1 资源感知切分与调度 12

2.3.2 协变混淆技术 15

2.3.3 统一调度接入机制 19

2.4 平台实现与运行流程 21

2.4.1 系统架构 21

2.4.2 系统运行流程与页面展示 22

2.4.3 国产加速平台适配 26

第三章 作品测试与分析 27

3.1 测试方案 27

3.1.1 测试目标与环境 27

3.1.2 评估维度与样本规模 27

3.2 平台功能与运行流程测试 28

3.3 边云协同切分机制调度策略评估 29

3.3.1 实例策略统计 29

3.3.2 资源扰动下的策略响应 30

3.4 隐私保护大模型推理性能评估 30

3.4.1 协变混淆链路性能与基线对比 30

3.4.2 带宽敏感性 32

3.4.3 并发鲁棒性与长上下文扩展 32

3.5 混淆数据安全评估 34

3.5.1 L1：唯密文攻击下的内容保护 35

3.5.2 L2：元数据侧信道与多请求关联 37

3.5.3 跨方案安全风险对比 38
3.6 方案对比 38
第四章 创新性说明 41
4.1 资源感知细粒度大模型切分机制 41
4.2 基于协变混淆的隐私保护推理方案 41
4.3 统一调度接入与国产化平台适配 42
第五章 总结 44
参考文献 46

图 目录

图 1.1 现有推理与部署技术方案的能力与局限 6
图 1.2 PrivLLM 平台核心能力架构 7
图 2.1 PrivLLM 系统架构 10
图 2.2 协变混淆推理端到端流程 21
图 2.3 模型切分与加载示意图 23
图 2.4 模型选择与会话就绪页面 23
图 2.5 层级注意力头与 FFN 切分详情 24
图 2.6 推理响应的明文恢复与云端混淆词元对照视图 24
图 2.7 边端 GPU 节点资源监控 25
图 2.8 云端 GPU 节点资源监控 25
图 2.9 昇腾 910B4-1 节点运行监控页面 26
图 3.1 样本分布概览 28
图 3.2 并发扩展测试结果 33
图 3.3 长上下文扩展测试结果 33

表 目录

表 1.1 大模型推理部署模式定性对比 9
表 3.1 动态切分实例策略统计 29
表 3.2 资源扰动条件下的切分策略复算 30
表 3.3 协变混淆链路推理性能 31
表 3.4 不同推理链路效率对比 31
表 3.5 tc HTB 链路限速对混淆切分链路的影响 32
表 3.6 昇腾 910B4-1 平台推理性能 34
表 3.7 攻击者能力分层与对应实验 35
表 3.8 唯密文攻击实验结果 35
表 3.9 词表置换的密码学性质验证 36
表 3.10 元数据侧信道强度评估 37
表 3.11 跨方案安全风险定量对比 38
表 3.12 PrivLLM 与代表性安全推理方案的多维度对比 39

摘要

大语言模型（Large Language Models, LLMs）正广泛应用于政务问答、医疗辅助、金融风控与工业智能终端等生产场景，但在真实部署中长期面临三重挑战：边端显存与算力难以独立承载完整大模型；明文直接进入云端会使政务材料、病例、交易记录等敏感内容暴露于云端；现有安全推理方案（安全多方计算、同态加密、可信执行环境等）在计算、通信或硬件覆盖率上存在显著瓶颈，难以工程化落地。

针对上述挑战，本作品设计并实现了**隐私保护的边云协同大模型推理平台**（Privacy-Preserving Edge-Cloud Collaborative LLM Inference Platform，PrivLLM）。平台面向边端可信、云端半可信且可能泄露隐私信息的应用场景，将边端本地恢复作为核心安全约束，并将三条技术主线统一于同一推理闭环：**（1）资源感知细粒度切分**：以 Transformer 层内注意力头与前馈网络子模块（Feed-Forward Network，FFN）为最小调度单元，结合显存上限、网络往返时延与云端负载动态分配边云分工；**（2）基于协变混淆的隐私保护推理**：先对输入词元做随机词表置换，再对模型权重做与之配套的可逆变换，使云端只能在混淆词元上完成与明文等价的推理，恢复密钥始终保留在边端，云端在整个推理过程中仅观察混淆词元；**（3）统一调度与国产化适配**：同一份切分策略在运行时自动决定加载明文推理模块还是混淆推理模块，边端缺少密钥时直接终止服务，防止安全机制被绕过。该平台已在 NVIDIA GPU 与华为昇腾 910B4-1 两种硬件平台上完成端到端实测。

本平台已适配 Llama-3.2-3B-Instruct、DeepSeek-R1-Distill-Qwen-1.5B、BERT 等主流模型架构，在真实边云硬件与多类数据集上完成系统评估。900 条请求压测下，协变混淆链路解码吞吐达 121.68 词元/s，与明文切分基线 121.89 词元/s 基本持平，端到端延迟为 5.437 s；该延迟差异主要来自网络预填充阶段，而非混淆计算本身。在 1100 条提示、共 52575 个对齐的明文–混淆词元对上，按照云端真实能力组织多组安全评估实验，唯密文场景下混淆词元表面与明文的严格相等率为 0.00%、8 类敏感标识符零泄漏、频率分析单词元 top-1 复原率不超过 1.6%、长度相关系数仅 0.083；在昇腾 910B4-1 平台上 500 条请求全部成功，P95（95 百分位）延迟 0.75 s，总吞吐 56.42 词元/s。实验范围内未观察到推理精度损失与明显性能退化，平台在异构算力环境中的迁移能力得到验证。本平台为政务、医疗、金融、工业等隐私敏感场景下的大模型落地提供了一条兼顾安全、效率与可用性的可行路径。

关键字： 大语言模型　边云协同推理　协变混淆　隐私保护　资源感知调度　国产化适配

Abstract

Large Language Models (LLMs) are widely applied in high-value scenarios such as government services, healthcare assistance, financial risk control, and industrial intelligent terminals, yet real-world deployment faces three persistent challenges: edge devices lack the memory and compute to run full LLMs locally; plaintext cloud inference exposes sensitive content such as medical records and transaction data to the remote provider; existing privacy-preserving inference solutions based on secure multi-party computation, homomorphic encryption, or trusted execution environments still suffer from prohibitive computation/-communication overhead or limited hardware availability, hindering practical deployment.

To address these challenges, this work designs and implements the **Privacy-Preserving Edge-Cloud Collaborative LLM Inference Platform** (PrivLLM). Under the threat model where the edge/trusted side is trusted and the cloud is privacy-curious while the trusted side performs recovery, PrivLLM integrates three technical threads into a single closed-loop inference pipeline: **(1) Resource-aware fine-grained partitioning** that schedules Transformer layers at the granularity of individual attention heads and feed-forward network (FFN) sub-modules, dynamically assigning work between edge and cloud subject to memory caps, network round-trip time, and cloud load; **(2) Covariant-obfuscation-based privacy-preserving inference** that first applies a random vocabulary permutation to input tokens and then coordinates the model weights with a matching invertible transform, so that the cloud performs equivalent inference on obfuscated tokens, recovery keys remain on the trusted side, and the cloud observes only obfuscated tokens throughout the inference process; **(3) Unified scheduling with domestic accelerator support**, where one partition policy automatically selects either the plaintext inference module or the obfuscated inference module at runtime—the edge terminates the service when the key is absent, preventing the secure mechanism from being silently bypassed. The platform has been end-to-end evaluated on both NVIDIA GPUs and Huawei Ascend 910B4-1.

The platform has been adapted to Llama-3.2-3B-Instruct, DeepSeek-R1-Distill-Qwen-1.5B, and BERT architectures, and is evaluated on real edge-cloud hardware with multiple datasets. Under a 900-request load test the obfuscated pipeline achieves a decoding throughput of **121.68 token/s**, matching the 121.89 token/s plaintext-split baseline within measurement noise, with an end-to-end latency of 5.437 s; this latency is dominated by network-

side prefill rather than obfuscation overhead. Across 1100 prompts totaling 52575 aligned plaintext–obfuscated token pairs, multiple security evaluations organized under the realistic L1/L2 threat model show that under ciphertext-only observation the strict surface-match rate is 0.00%, 8 categories of structured identifiers leak at 0.00%, frequency-analysis single-token top-1 recovery stays at or below 1.6%, and the length correlation coefficient is only 0.083. On Ascend 910B4-1, 500 requests succeed with a P95 latency of 0.75 s and aggregate throughput 56.42 token/s. Within the evaluated scope, no accuracy loss or significant performance degradation is observed. PrivLLM offers a deployable path for privacy-sensitive LLM applications on heterogeneous hardware.

Keywords: Large Language Models Edge-Cloud Collaborative Inference Covariant Obfuscation Privacy Preservation Resource-Aware Scheduling Domestic Accelerator Adaptation

第一章 作品概述

1.1 背景分析

大语言模型（Large Language Models, LLMs）已广泛应用于政务、医疗、金融、工业物联网与智能终端等高价值业务场景。Stanford HAI 发布的 2025 年 AI Index 报告指出，2024 年部署人工智能的组织比例由 2023 年的 55% 上升至 78%，达到 GPT-3.5 水平系统的推理成本在两年内下降逾 280 倍[1]。大模型推理服务正从通用问答走向核心业务流程，数据隐私、服务可靠性与部署成本随之成为落地阶段必须同时面对的约束。

当前主流 LLM 服务普遍采用云端集中部署或开放 API 调用方式，用户必须将原始提示词、业务材料与运行日志提交至云端服务器，构成集中式明文推理模式。该模式在带来便捷性的同时，使输入语义、中间特征、KV 缓存与输出序列同时暴露于云端基础设施。近年来的安全事件表明，上述风险真实存在：2025 年 1 月，Wiz Research 披露 DeepSeek 一处可公开访问的 ClickHouse 数据库泄露了约一百万行日志流，其中包含完整聊天记录、密钥与运行元数据[2]。NIST 在 NIST AI 600-1《生成式人工智能风险管理框架》中将 LLM、云服务与第三方供应链共同列为跨行业风险源[3]；OWASP LLM Top 10 2025 将“敏感信息泄露”列为首要风险[4-5]；除显式输入输出外，向量嵌入、隐藏状态与 KV cache 等运行时中间状态也已经被证明产生了潜在的安全风险[6-7]。

隐私威胁贯穿在线推理的输入、输出、缓存与日志全链路；与此同时，边端设备显存、算力与能耗预算有限，难以独立承载完整大模型推理；完全依赖云端又会扩大敏感上下文暴露范围。已有边云协同研究表明，深度模型推理可依据模型结构、设备能力与网络状态进行切分[8-10]。然而，将上述思想落地于大语言模型的隐私敏感场景，仍面临三大挑战：

挑战一：边端算力受限，如何在不将敏感内容完全上云的前提下充分利用云端算力？实际业务场景对大模型推理质量要求较高，但边端显存与算力难以稳定承载完整模型；若把全部计算交给云端，敏感上下文就会进入云端服务链路。现有边云协同方案主要关注延迟和能耗优化，切分粒度多为整层，难以匹配 Transformer 解码器内部多头注意力与前馈网络的计算差异；在需要防范云端隐私泄露的场景中，还缺少系统的解决思路。

挑战二：如何在保持在线推理效率的前提下，降低云端对用户明文的可见性？真实服务中的输入提示词、生成输出、KV cache、隐藏状态、embedding 与监控日志均可能成为攻击目标[7,11]。近期关于表示反演与隐藏状态恢复的研究表明，普通 embedding 混淆、加噪或简单置换并不等价于隐私安全[12-15]；而安全多方计算、同态加密等密码学方案虽有严谨理论保证，但在高维张量与复杂非线性算子上的额外开销使在线推理难以接受。这要求一条“效率接近明文、云端看不到原始内容”的中间路线。

挑战三：如何把切分调度、隐私保护与国产化适配整合到同一套可落地的系统里，避免安全机制在实际运行中被绕开或失效？现有安全推理方案大多停留在算法原型或单个组件上，缺少面向真实部署的统一调度后端、运行时控制、资源监控和安全审计流程。一旦涉及多设备、多模型、不同网络条件和国产加速平台适配，系统必须在性能、隐私边界和运维可观测性之间形成闭环；否则，安全模块很容易在配置错误、模型重新导出或手工部署时被悄悄绕过，从而无法实现隐私保护功能。

针对上述三大挑战，本作品设计并实现了**隐私保护的边云协同大模型推理平台**（Privacy-Preserving Edge-Cloud Collaborative LLM Inference Platform，PrivLLM）。

1.2 相关工作

围绕大语言模型推理过程的隐私保护与多端协同部署，现有工作主要沿四条技术路线展开。

（1）云端大模型服务与隐私风险治理。 NIST、OWASP 等机构系统梳理了 LLM 应用中的隐私威胁：用户输入、模型输出、向量表示、应用上下文与运行日志均可能成为敏感信息暴露范围[3-5]。Staab 等人进一步实证表明，LLM 可仅从推理时文本推断用户位置、收入、性别等个人属性，常规匿名化与对齐措施不足以消除推断式隐私泄露[11]。该类工作明确了威胁模型，但未提供在系统层降低威胁的实现方案。

（2）边云协同与模型切分推理。Neurosurgeon 首次系统说明按层切分深度神经网络可在端侧能耗、推理延迟与云端负载之间形成 Pareto 权衡[8]；CE-CoLLM 将该思想拓展至 LLM 场景，提出自适应边云协同调度[9]；近期关于边端小模型与云端大模型协同推理的研究进一步讨论了任务分配与卸载策略[10]。上述工作普遍以性能与成本为主要目标，未将“云端可见数据范围控制”作为系统约束纳入同一闭环。

（3）密码学与可信执行环境隐私推理。基于安全多方计算（MPC）与同态加密（HE）的方案能够提供较强的安全保护。通用框架方面，ABY3[16]、MP-SPDZ[17]、CrypTen[18]为机器学习算子提供了密态计算基础;面向 Transformer/LLM 的专用协议方面，Iron[19]、MPCFormer[20]、CipherGPT[21]、BumbleBee[22]、BOLT[23]、PUMA[24] 与 East[25] 持续压

缩密态推理开销，但在生成阶段仍面临大量额外开销，难以满足低延迟在线推理需求。可信执行环境（TEE）路线如 PipeLLM[26] 通过硬件隔离在接近明文开销下提供机密推理，但受限于可信硬件覆盖率与远程验证等配套机制，难以全面适配多样化的部署环境，尤其是国产加速生态。

（4）协变混淆与可逆表示变换类轻量方案。为规避纯密态计算的高昂开销，一类工作转向可逆表示变换或随机置换：TextHide[27]、DP-Forward[28] 通过实例混合或差分隐私噪声保护中间表示；另有工作提出基于随机置换的安全 Transformer 推理协议[29]。本文将这类保持推理等价、但把恢复材料保留在客户端的轻量路线统称为协变混淆（Covariant Obfuscation）[30]。现有静态表示变换方案多将变换定位为模型导出阶段的静态机制，尚未回答边云资源调度、边端密钥管理、运行时完整性校验与国产化平台适配等系统层问题——而表示反演工作[12-15]恰恰从反面印证：一旦变换材料或可逆路径暴露于不可信侧，隐私即不再成立，因此，系统必须同时锁住恢复密钥和执行路径，避免变换本身被逆向还原。

综上，现有工作尚未形成兼顾效率、安全与部署可行性的完整方案：MPC/HE 路线计算开销过高，TEE 路线受可信硬件覆盖率制约，协变混淆原型缺乏边云调度与运行时可追踪性。本作品正是针对这一空白，将协变混淆从静态变换扩展为受动态调度驱动、可运行时验证、并适配国产算力的完整方案。现有方案的能力与局限如图 1.1 所示。

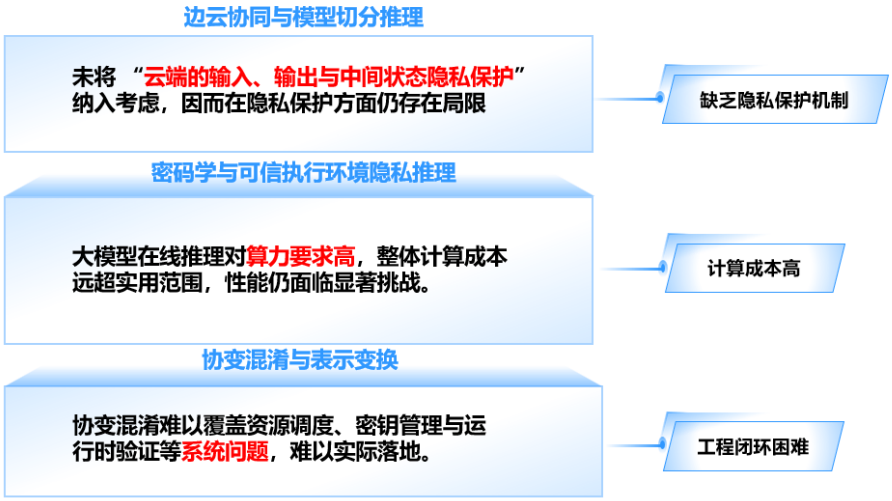


图 1.1　现有推理与部署技术方案的能力与局限

1.3 作品特色

面向上述三大挑战，PrivLLM 以资源感知细粒度切分为性能主线、以协变混淆为隐私主线，并通过统一调度层将两者接入同一推理闭环，同时完成国产化平台适配。整体设计思路如图 1.2 所示：

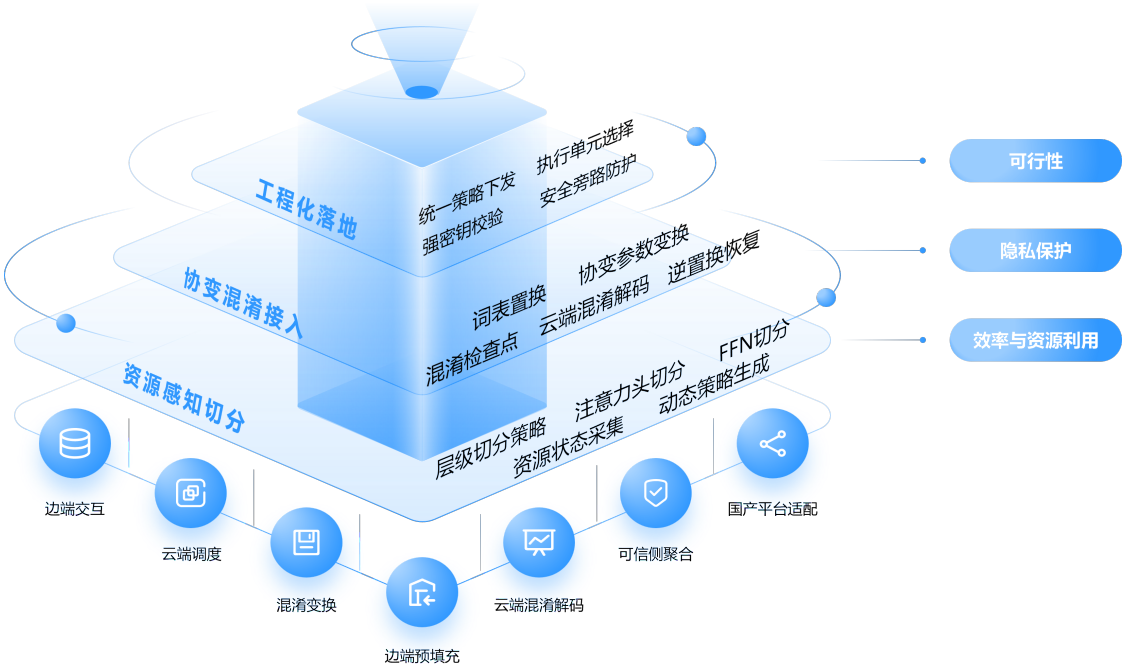


图 1.2　PrivLLM 平台核心能力架构

特色一：资源感知细粒度大模型切分机制。以 Transformer 层内注意力头与 FFN 子模块为最小调度单元，调度后端实时采集边云显存/算力、网络往返时延与模型负载，生成层内注意力头级分配向量并经统一调度层下发至边云运行时。与按整层迁移的粗粒度方案相比，注意力头级动态分配可按网络与设备条件弹性调整，在 Llama-3.2-3B 实测中协变混淆链路取得 121.68 词元/s 解码吞吐，与明文切分基线 121.89 词元/s 基本持平。

特色二：基于协变混淆的隐私保护推理方案。将协变混淆整合进边云推理链路：边端将明文词元经词表置换映射至混淆词元空间，协同可逆变换同步映射模型参数，云端全程在混淆视角下完成推理，边端聚合器持有逆置换并完成输出恢复。恢复材料始终不离开边端，云端不持有任何明文–混淆词元映射关系；由于协变变换保持计算等价性，实验范围内未观察到推理精度损失。在 1100 条提示、52575 个对齐词元对上、多组不同威胁模型层级（L1/L2）的安全评估实验中，混淆词元表面与明文的严格相等率为 0.00%，8 类敏感标识符零泄漏，频率分析 top-1 复原率不超过 1.6%。

特色三：统一调度接入与国产化平台适配。构建覆盖边端交互入口、调度后端、边云运行时调度层与资源监控面板的完整闭环：同一份层级切分策略既驱动模型分片加载，又触发混淆推理模块的动态选择；边端在密钥缺失时拒绝创建混淆推理模块，防止安全机制被悄悄绕过；从会话初始化、策略计算、模型加载到推理完成全程留有日志，每一环节可经界面或日志回溯复核。系统在 NVIDIA GPU 与昇腾 910B4-1 双平台完成端到端实测，昇腾平台 500 条请求全部成功，P95 延迟 0.75 s。

1.4 应用前景分析

1.4.1 应用场景

PrivLLM 为隐私敏感场景下的大模型推理提供了基础平台，典型应用场景包括：

高隐私要求的政务与金融场景。在政务问答、金融风控等领域，用户对话、交易记录、账户信息与公文材料具有较高隐私敏感性。依托边云协同的隐私保护推理，机构可在降低敏感上下文直接暴露风险的前提下完成智能问答、合规审计、风险评估与智能客服等任务，在控制额外响应延迟的同时满足业务实时性要求。

医疗辅助与健康数据处理。医疗记录、问诊对话与检查报告包含高度敏感的个人健康信息。PrivLLM 使敏感医疗文本在边端完成置换后再进入云端推理链路，恢复密钥保留在医院或边端，云端始终处理混淆词元，为医疗场景的大模型应用提供可控的隐私边界。

工业物联网与具身智能场景。自动驾驶车辆、工业机器人、边缘安防等终端通常对推理延迟与能耗有严格约束，同时其感知数据与控制语义涉及商业机密和系统安全。资源感知切分机制可按网络状态与设备负载动态调整边云执行比例，协变混淆链路进一步降低云端对任务文本或环境描述的直接可见性。

国产化与自主可控部署场景。在关键信息基础设施与政企私有化部署中，大模型推理系统需要与国产 AI 加速生态深度适配。PrivLLM 已在昇腾 910B4-1 平台上完成主流推理链路的端到端运行与监控，运行基于 CANN、MindIE 与 torch_npu 等国产软件组件[31-32]，500 条请求全部成功，为自主可控环境下的安全推理落地提供了实际验证。

上述场景的共同结构是：边端有数据、云端有算力、二者之间需要可控的隐私边界。PrivLLM 的边云切分与协变混淆闭环正是针对这一结构设计的，已具备实际部署条件。

1.4.2 市场价值

合规与市场需求。欧盟 GDPR、加州 CCPA 以及我国《个人信息保护法》《数据安全法》《生成式人工智能服务管理暂行办法》共同对企业的数据处理透明度、可控性与最小化披露提出明确要求；公众对将敏感数据上传至公有云 LLM 服务的顾虑持续上升。表 1.1 从部署模式维度给出不同方案在隐私保护、计算效率与落地门槛三方面的定性对比。

表 1.1　大模型推理部署模式定性对比

部署模式	云端可观察数据范围	计算效率	边端门槛	云端依赖
纯边端部署	不可见	受边端算力限制	高	低
纯云端部署	明文直接进入云端	算力充足、吞吐高	低	高
边云切分（无混淆）	部分中间特征	兼顾延迟与扩展算力	中	中
PrivLLM	仅见混淆词元，恢复材料留在边端	接近云端明文推理	中	中低

与传统集中式明文云推理相比，PrivLLM 在边端保留用户原始输入与逆置换密钥，仅向云端发送混淆词元空间中的序列，从结构上降低用户输入和输出内容的直接暴露风险，同时通过细粒度切分充分利用云端算力。

与纯密码学 MPC/HE 路线相比，PrivLLM 在云端存在隐私泄露风险和边端可信的威胁模型下提供与现有 LMaaS 推理基础设施兼容的隐私保护方案，更适合低延迟、低改造成本的在线推理场景。现有通用 MPC/HE 框架因额外开销难以满足在线交互，TEE 方案受可信硬件覆盖率制约、难以覆盖多样化的部署环境，尤其是国产加速生态，市场急需一条兼顾安全与效率的中间路线，PrivLLM 正是针对这一缺口设计的。

与静态协变混淆原型相比，PrivLLM 进一步将其接入资源调度后端与边云运行时调度层，使协变混淆从“模型导出阶段的一次性变换”扩展为“动态调度策略可触发、可追踪、可验证的运行时机制”，并通过运行时完整性校验与安全评估形成可量化的隐私评估闭环。

第二章 作品设计与实现

2.1 方案总体设计

PrivLLM 以“边端可信、云端存在隐私泄露风险、边端完成输出恢复”为基本威胁模型，在该模型下融合资源感知细粒度切分与协变混淆机制，构建从用户输入、动态调度、混淆推理到输出恢复的完整闭环。平台系统架构如图 2.1 所示，包含边端交互、协变混淆变换、云端调度与监控、边云切分运行时以及边端聚合五类核心模块；以下按三条协同的技术主线展开说明：

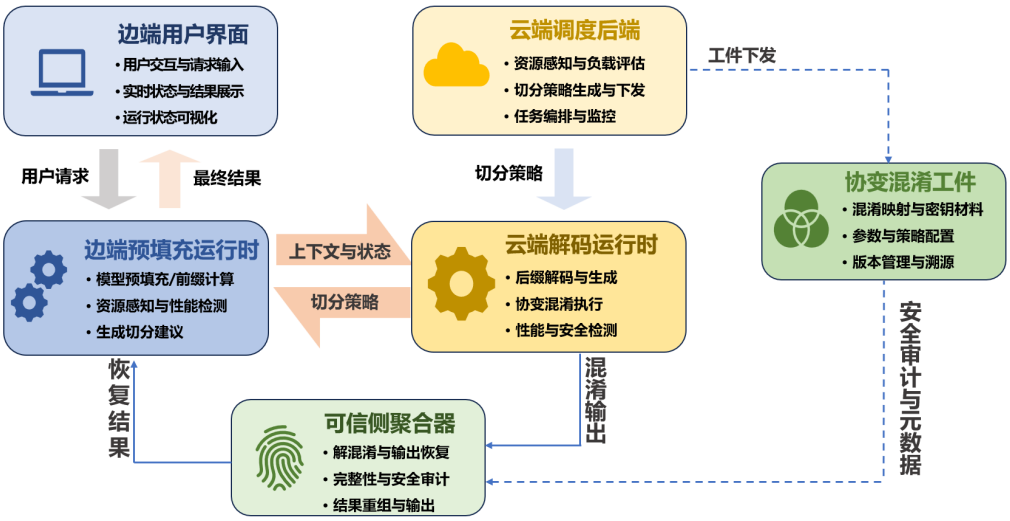


图 2.1　PrivLLM 系统架构

（1）资源感知细粒度切分。将 Transformer 解码器[33]的切分粒度由整层划分扩展为层、注意力头和前馈网络三个层级的子模块，通过统一的层级切分策略向量描述每个子模块在边端或云端的执行位置。云端调度器依据边端显存上限、云端设备状态与运行时资源使用情况实时生成实时策略，并经统一调度层下发至边云运行时。

（2）基于协变混淆的隐私保护推理。设计基于词表置换与协同可逆参数变换的协变混淆机制：边端在发送前对词元标识执行词表置换，云端加载经协同变换导出的混淆模型并在混淆词元空间上完成等价推理，边端聚合器利用逆置换恢复输出。云端在整个推理过程中仅观察混淆词元与混淆中间状态，恢复密钥始终不离开边端。本文档统一将经词表置换 π 映射后的词元称为混淆词元，以区别于经密码学加密得到的密文——协变混淆并非密码学意义上的加密算法，而是一种保持计算等价性的可逆表示变换。

（3）统一调度接入与运行时控制。针对安全模块易被配置失误或手工部署绕过的问题，构建基于统一策略表达的运行时控制机制：同一份层级切分策略既驱动边云模型分片加载，也触发协变混淆推理模块的动态选择；边端在缺少客户端密钥时拒绝创建混淆推理模块，防止系统悄悄退化为不完整的安全路径；运行时对关键环节留有日志，可经界面或资源监控面板复核。

2.2 大模型推理与 Transformer 架构

大语言模型的一次推理过程可分为两个阶段：**预填充阶段**（prefill）将输入提示词元序列一次性送入模型，构建各层 KV 缓存；**解码阶段**（decode）以自回归方式逐词元生成后续序列，每步仅处理一个新词元并更新 KV 缓存。

Transformer 解码器[33]由嵌入层、L 个堆叠的解码块与输出语言模型头（LM Head）构成。每个解码块包含：

1. **多头自注意力（Multi-Head Attention, MHA）**：将隐藏状态投影为 Query/Key/Value，经缩放点积注意力与多头拼接后，由输出投影 W^O 映射回隐藏维度；
2. **前馈网络（Feed-Forward Network）**：通常为两层线性变换加一个非线性激活（如 SwiGLU），参数量与计算量通常显著大于单注意力头；
3. **归一化层**：RMSNorm（Root Mean Square Layer Normalization，或 LayerNorm, Layer Normalization）[34]对隐藏状态按均方根归一化，再由逐维可学习缩放参数 γ 调制；
4. **位置编码（Positional Encoding）**：主流开源 LLM 普遍采用旋转位置编码（RoPE）[35]，通过对 Query/Key 子空间按位置施加二维旋转注入位置信息。

边云协同切分推理的基本思想是：将上述不同子模块分配至边端与云端分别执行，中间结果通过网络传输。设解码器层数为 L，每层注意力头数为 H，则层级切分策略可形式化为

$$\mathcal{P} = \{(h_{\ell,1}, h_{\ell,2}, \ldots, h_{\ell,H}, f_\ell)\}_{\ell=1}^{L}, \quad h_{\ell,i} \in \{0,1\},\ f_\ell \in \{0,1,2\}, \tag{2.1}$$

其中 $h_{\ell,i}=0$ 表示第 ℓ 层第 i 个注意力头在边端执行，$h_{\ell,i}=1$ 表示在云端执行；f_ℓ 表示第 ℓ 层 FFN 的执行位置，取 0、1、2 分别对应边端执行、云端执行与边云拆分执行。该形式化表达为调度算法提供了比“整层迁移”更丰富的决策自由度。

需要特别说明 **RoPE 的协变兼容性**：RoPE 在注意力头内部的 Query/Key 子空间上对每对二维分量施加相同角度的旋转矩阵。在本平台的实现中，协变变换对每个注意力头的 Q/K 保留 RoPE 的二维旋转维度对结构，并按子空间维度独立施加正交旋转，具体见 2.3.2 节注意力模块的协变变换，使 RoPE 二维旋转与协变正交变换可交

换，从而保持注意力分数与明文计算一致；该等价性在模型导出后的运行时等价性验证中与其他算子一起进行逐词元校验。

2.3 关键技术

2.3.1 资源感知切分与调度

要让大模型在边端显存有限、云端负载波动、网络质量时好时坏的环境下能够运行，调度器必须在运行时动态决定每一层的每个注意力头和 FFN 放在哪里。本节先建立边端显存、网络传输与云端算力的量化约束，再介绍如何在这些约束下训练细粒度切分策略。

资源约束建模。设边端总显存、已用显存和可用显存分别为 M_e、M_e^{used} 和 $M_e^{\text{avail}} = M_e - M_e^{\text{used}}$；云端算力与负载利用率分别为 C_c 和 u_c；网络往返时延与可用带宽分别为 rtt 和 bw。一次请求的参数包括层数 L、注意力头数 H、隐藏维度 d、每头维度 $d_k = d/H$ 以及提示长度 n_{prompt}。

在预填充阶段，单个注意力头需要在边端缓存 Key 和 Value 两部分状态，其显存开销可估算为

$$m_{\text{head}} = 2 \cdot d_k \cdot n_{\text{prompt}} \cdot b_{\text{dtype}}, \tag{2.2}$$

其中 b_{dtype} 为浮点精度字节数，fp16/bf16 取 2 字节。式 (2.2) 刻画了提示长度增长时，单个注意力头给边端带来的显存压力。实际训练时并不把动作压缩成一个全局头数再做硬截断，而是把显存占用比例、存储预算、队列状态等容量信息编码进状态，并在优化目标里惩罚超出边端能力的动作。对候选动作 a，其容量风险概括为

$$C_e(s,a) = \lambda_C \big[\rho_e(a) - \kappa_e(s)\big]_+^2 + \lambda_S \big[\rho_e(a) M_{\text{model}} - S_e\big]_+^2, \tag{2.3}$$

其中 $[x]_+ = \max(0, x)$，$\rho_e(a)$ 为动作对应的边端计算占比，$\kappa_e(s)$ 表示由边端 CPU、内存、GPU 利用率与队列长度估计的有效算力容量，M_{model} 为模型全部放在边端时的近似存储需求，S_e 为边端存储预算。

单头跨边云传输的中间激活量近似为

$$b_{\text{head}} = d_k \cdot n_{\text{prompt}} \cdot b_{\text{dtype}}, \tag{2.4}$$

对应单头传输时延 $\tau = b_{\text{head}}/bw$。

动态切分调度策略。 在资源约束建模的基础上，本平台采用“真实运行数据采集 + 监督预训练 + 近端策略优化（Proximal Policy Optimization, PPO）微调”的方式训练细粒度切分策略。这里的强化学习并不只是选一个全局边端头数，而是对每一层的每个注意力头和 FFN 分别给出位置决策，最终输出可直接下发至运行时的层级切分策略 $\mathcal{P}$。

状态空间。 调度器观测的状态 s_t 包括三类信息：第一类是请求与模型信息，包括提示长度、模型类型、层数和注意力头数；第二类是边端与云端运行状态，包括设备类型、CPU/内存/GPU 利用率、显存占用比例与队列长度；第三类是网络与边端容量信息，包括边端往返时延、云端往返时延、边云链路时延、估计带宽、丢包率、边端存储预算和存储压力。上述特征经归一化后拼接为固定维度状态向量，送入策略网络。

动作空间。 动作 a_t 由两部分组成：注意力头动作 $h_{\ell,i} \in \{0,1\}$ 表示第 ℓ 层第 i 个注意力头放在边端或云端；FFN 动作 $f_\ell \in \{0,1,2\}$ 表示第 ℓ 层 FFN 放在边端、云端或拆分执行。策略网络因此包含两个输出头：一个二分类概率输出头为所有 (ℓ, i) 产生注意力头分配概率，另一个三分类输出头为每层 FFN 产生执行位置概率；无效的层和头由模型掩码屏蔽。

奖励函数。 训练目标同时考虑首词元延迟、云端暴露面、边端容量约束和策略稳定性。设 $\rho_e(a)$ 与 $\rho_c(a)$ 分别为由注意力头和 FFN 分配加权得到的边端/云端计算占比，$B(a)$ 为层内拆分边界比例，$C_e(s,a)$ 为式 (2.3) 中的边端算力或存储超限惩罚，$G(\rho_e)$ 为边端占比软约束惩罚，$I(a,a^\star)$ 为对采集数据中低首词元延迟（Time-To-First-Token，TTFT）策略 $a^\star$ 的模仿奖励，则 PPO 微调阶段采用

$$\begin{aligned} J(s_t,a_t) &= \lambda_T T_{\text{proxy}}(s_t,a_t) + \lambda_P \rho_c(a_t)^p \\ &\quad + \lambda_B B(a_t) + C_e(s_t,a_t) + \lambda_G G(\rho_e(a_t)), \\ R(s_t,a_t) &= -J(s_t,a_t) + I(a_t,a^\star). \end{aligned} \tag{2.5}$$

其中 T_{proxy} 由提示长度、边云队列、链路时延、带宽、丢包率和实际采集到的 TTFT 共同构成，用于近似本次切分的首词元延迟代价；$\rho_c(a_t)^p$ 与 $B(a_t)$ 共同惩罚过多云端执行与过碎的层内拆分；C_e 防止策略把超过边端算力或存储预算的计算强行迁回边端。

训练方法。 训练分两阶段进行。第一阶段使用真实边云运行采集得到的数据集做监督预训练：采集脚本在给定状态下生成多个候选层级切分策略，实际运行首词元

生成，保留 TTFT 最低且满足边端占比约束的策略作为标签。第二阶段在该策略网络基础上进行 PPO 微调：从当前策略分布采样注意力头和 FFN 动作，计算奖励、价值函数、优势函数和截断替代目标函数，并加入行为克隆损失、边端占比期望惩罚和熵正则。训练后保存带状态维度、最大层数、最大头数和模型配置元数据的检查点；在线推理时只做一次策略网络前向传播和动作解码。

与已有工作的关系。 现有工作已将深度强化学习用于 DNN 推理的边云切分与调度：Edgent[36] 提出基于 DNN 分区与右尺寸化的设备–边缘协同推理框架；DNN Surgery[37] 采用动态自适应 DNN 手术方法，在运行时根据网络负载切换切分算法；SplitPlace[38] 将切分策略选择与设备放置分解为“先在若干候选切分方案中做在线试错选择、再由强化学习决定设备放置”的联合决策问题。本平台在这些工作的基础上，进一步将切分粒度细化至 Transformer 层内注意力头与 FFN 子模块级别，并将切分策略与协变混淆推理路径耦合进统一调度闭环。

算法 1 给出该训练与在线生成的完整流程：离线部分学习策略参数，在线部分把实时状态一次性解码为运行时可执行的层级切分策略。

算法 1 细粒度切分策略训练与在线生成

输入： 采集数据集 $\mathcal{D} = \{(s_j, a_j^\star)\}$；在线状态 s

输出： 层级切分策略 $\mathcal{P} = \{(h_{\ell,1}, \ldots, h_{\ell,H}, f_\ell)\}_{\ell=1}^{L}$

初始化共享 MLP、注意力头二分类概率输出头、FFN 三分类输出头与价值头

离线训练

for 监督预训练 epoch **do**

　用掩码 BCE/CE 损失拟合 $a^\star$，并加入边端占比软约束，更新 θ

end for

for PPO 微调 epoch **do**

　从 $\pi_{\theta_{\text{old}}}$ 采样 $h_{\ell,i}$ 与 f_ℓ，计算 $\log \pi_{\theta_{\text{old}}}(a|s)$

　由式 (2.5) 计算奖励 R，估计优势 $A = R - V_{\theta_{\text{old}}}(s)$

　用 clipped PPO 损失、价值损失、行为克隆损失、边端占比惩罚和熵正则更新 θ

end for

选择部署检查点 $\pi_{\theta^\star}$

在线生成

$(z_h, z_f) \leftarrow \pi_{\theta^\star}(\text{Encode}(s))$

for 所有有效 (ℓ, i) **do**

　$h_{\ell,i} \leftarrow \mathbb{I}\big[\sigma(z_{\ell,i}^h) > 0.5\big]$

end for

for 所有有效层 ℓ **do**

　$f_\ell \leftarrow \arg\max_{c\in\{0,1,2\}} z_{\ell,c}^f$

end for

return $\mathcal{P}$

2.3.2 协变混淆技术

定义 (协变混淆) 协变混淆（*Covariant Obfuscation*）是一种面向隐私保护大模型推理的可逆变换方法：对输入词元空间与模型参数空间施加协同的可逆变换，使模型在变换后的表示上完成与明文等价的推理，同时让服务端仅观察到变换后的表示，无法直接获知用户原始输入与输出内容。

设明文词元序列为 $x = (x_1, \ldots, x_n)$，词表大小为 V，明文推理模型为 F。客户端

随机生成词表置换

$$\pi : \{0, 1, \ldots, V-1\} \to \{0, 1, \ldots, V-1\}, \tag{2.6}$$

并安全保存逆置换 π^{-1}。边端发送至云端的混淆词元序列为

$$x'_i = \pi(x_i), \quad i = 1, \ldots, n. \tag{2.7}$$

云端加载经协同变换导出的混淆模型 F'，在混淆词元空间中生成混淆输出 $y' = F'(x')$；边端聚合器通过逆置换恢复明文输出：$y = \pi^{-1}(y')$。若 F 与 F' 满足协变约束

$$F'(\pi(x)) = \pi(F(x)), \tag{2.8}$$

则 $\pi^{-1}(F'(\pi(x))) = F(x)$，即混淆推理与明文推理在词元空间产生一致输出。

式 (2.8) 是协变混淆链路的正确性目标。词表置换通过密码学安全随机源生成，参数变换通过隐藏维度置换与可逆缩放矩阵组合构造，使嵌入层、注意力模块、前馈网络、归一化层与输出头在变换前后保持计算等价性。

设明文模型与混淆模型分别可写为

$$\begin{aligned} F &= \text{LMHead} \circ f_L \circ \cdots \circ f_1 \circ \text{Embed}, \\ F' &= \text{LMHead}' \circ f'_L \circ \cdots \circ f'_1 \circ \text{Embed}'. \end{aligned} \tag{2.9}$$

则 F' 需使三类模块分别满足局部协变关系：

$$\begin{aligned} \text{Embed}' \circ \pi &= S \circ \text{Embed}, \\ f'_\ell \circ S &= S \circ f_\ell, \qquad \ell = 1, \ldots, L, \\ \text{LMHead}' &= \pi \circ \text{LMHead} \circ S^{-1}. \end{aligned} \tag{2.10}$$

由式 (2.10) 中的局部协变关系可知，对任意输入 x 均有 $F'(\pi(x)) = \pi(F(x))$。

模型参数的协同变换。 为使混淆模型 F' 满足上述局部协变关系，系统需要生成一组可逆的隐藏维度变换参数。设隐藏维度为 d，随机种子 s 由操作系统密码学安全随机源生成。系统由种子 s 在隐藏维度上生成随机置换 $\sigma \sim \mathcal{U}(\mathfrak{S}_d)$，并在每个维度上独立采样非零缩放因子 $a_i \in [\alpha, \beta]$，$a_i \neq 0$，由此得到置换矩阵 P_σ 与对角缩放矩阵 $D_a = \text{diag}(a_1, \ldots, a_d)$。隐藏空间主变换及其逆为

$$S = P_\sigma D_a, \qquad S^{-1} = D_a^{-1} P_\sigma^\top. \tag{2.11}$$

该变换将作用于模型中所有可训练参数，使云端在不知道 S 的情况下无法通过检查点权重反推明文模型结构。基于消融观察：隐藏维度缩放幅度超过 $\pm 5\%$ 在部分

层会引入数值不稳定，而前馈中间维度对缩放更不敏感；因此本实现对隐藏维度与注意力 Q/K 子维度取 $[\alpha, \beta] = [0.97, 1.03]$，前馈中间维度取 $[0.92, 1.08]$，并通过算法 2 的验证确认该区间在当前模型与精度下不破坏协变约束。

为增加云端仅观察检查点权重时的静态逆向难度，系统额外引入扩展矩阵

$$E \in \mathbb{R}^{d \times r}, \qquad F_{\text{ext}} \in \mathbb{R}^{r \times d}, \tag{2.12}$$

其中 $r \in [d/16, d/8]$，在模型导出阶段与同层线性权重拼接写入混淆检查点。r 仅客户端知晓，E 与 F_{ext} 不进入前向通道，不影响推理正确性。以上变换参数可统一表示为

$$K = \left(\pi, \pi^{-1}, \sigma, a, S, S^{-1}, E, F_{\text{ext}}\right). \tag{2.13}$$

线性模块。对任意线性子模块 $g(h) = Wh + b$，在输入输出均处混淆隐藏空间时，其混淆版本为

$$g'(\tilde{h}) = Sg(S^{-1}\tilde{h}) = SWS^{-1}\tilde{h} + Sb, \tag{2.14}$$

对应权重与偏置变换 $W' = SWS^{-1}$，$b' = Sb$。该式统一解释了嵌入、输出头、注意力投影与前馈网络等线性子模块的变换来源。

注意力模块。设第 ℓ 层输入隐藏状态为 $h_{\ell-1}$，其混淆形式为 $\tilde{h}_{\ell-1} = Sh_{\ell-1}$。在每个注意力头 i 的 d_k 维子空间内独立构造一个由随机二维旋转角生成、并保持二维旋转维度对结构的块对角正交矩阵 H_i，并据此映射 Q/K 投影权重：

$$W_{h_i}^{Q\prime} = H_i W_{h_i}^{Q} S^{-1}, \qquad W_{h_i}^{K\prime} = H_i W_{h_i}^{K} S^{-1}, \tag{2.15}$$

从而 $Q_i' = Q_i H_i^{-1}$，$K_i' = K_i H_i^{-1}$。由于 H_i 正交，

$$Q_i' K_i'^{\top} = Q_i H_i^{-1} H_i^{-\top} K_i^{\top} = Q_i K_i^{\top}, \tag{2.16}$$

即注意力分数与明文完全一致——不仅 argmax 保持等价，整个 softmax 分布也逐位保持不变。对 Value 投影，令 $W_{h_i}^{V\prime} = W_{h_i}^{V} S^{-1}$，把输入侧的 S 变换吸收进权重矩阵后 $V_i' = V_i$；对输出投影，令 $W^{O\prime} = SW^{O}$。综合四个子模块，多头注意力整体满足

$$\widetilde{\text{MHA}}(\tilde{h}_{\ell-1}) = S \cdot \text{MHA}(h_{\ell-1}).$$

RMSNorm。 RMSNorm 前向计算为

$$\text{RMSNorm}(h; \gamma) = \gamma \odot \frac{h}{\|h\|_{\text{rms}}}, \quad \|h\|_{\text{rms}} = \sqrt{\frac{1}{d}\sum_{i=1}^{d} h_i^2}. \tag{2.17}$$

直接对输入施加 $S = P_\sigma D_a$ 后，$\|Sh\|_{\text{rms}}$ 一般不等于 $\|h\|_{\text{rms}}$（因缩放因子 a_i 不恒为 1）。为此对可学习缩放参数 γ 施加同步变换：令 $\gamma' = S\gamma$（即 $\gamma'_{\sigma(i)} = a_i\gamma_i$），可验证

$$\text{RMSNorm}(Sh;\gamma') = S \cdot \text{RMSNorm}(h;\gamma) \tag{2.18}$$

在数学上成立。考虑到浮点数值误差与逐层累积，本平台额外采取两项措施：（1）将 $[\alpha,\beta]$ 收窄至前述较保守区间；（2）在模型导出与加载前通过算法 2 对归一化层输出进行词元级相对误差校验，超过阈值即拒绝加载。

RoPE。 RoPE 在 Q/K 的 RoPE 二维旋转维度对上施加同角度二维旋转。本平台对每个注意力头的 Q/K 子空间采用逐头的二维块对角正交矩阵 H_i，使其在结构上与 RoPE 的二维旋转维度对对齐，从而与 RoPE 旋转可交换，保证注意力分数 $Q'_iK'^{\top}_i = Q_iK_i^{\top}$ 在变换前后一致。运行时等价性验证中对位置编码正确性进行了词元级校验，实测范围内未发现误差。

运行时等价性验证。 不同模型的具体实现、算子融合路径与浮点精度差异都可能引入实际偏差。平台在模型导出后、部署前执行算法 2，用验证样本集做逐词元比对与逐层相对误差校验，将工程实现偏差拦截在发布前：

算法 2 协变等价性运行时验证算法

输入： 明文模型 F（边端持有），混淆模型 F'（云端持有）；词表置换 π 及其逆 π^{-1}；验证样本集 $\mathcal{D}_{\text{val}} = \{p_1, \ldots, p_N\}$（默认 $N \geq 100$）；容忍阈值 τ（逐词元不等价比例上限，默认 $\tau = 0$ 严格等价；最大相对误差 $\epsilon_{\max}$）

输出： 验证结果（通过/失败）及每样本统计

初始化通过计数器 $c_{\text{pass}} \leftarrow 0$，差异计数器 $c_{\text{diff}} \leftarrow 0$
for 每条验证提示 $p_i \in \mathcal{D}_{\text{val}}$ **do**
    $x_i \leftarrow \text{Tok}(p_i)$ ▷ 明文词元化
    $y_i \leftarrow \text{argmax}(F(x_i))$ ▷ 明文贪婪解码
    $x'_i \leftarrow [\pi(x_{i,j})]_{j=1}^{|x_i|}$ ▷ 词表置换
    $y'_i \leftarrow \text{argmax}(F'(x'_i))$ ▷ 混淆模型推理
    $\hat{y}_i \leftarrow [\pi^{-1}(y'_{i,j})]_{j=1}^{|y'_i|}$ ▷ 逆置换恢复
    if $\hat{y}_i = y_i$ **then**
        $c_{\text{pass}} \leftarrow c_{\text{pass}} + 1$
    else
        $c_{\text{diff}} \leftarrow c_{\text{diff}} + 1$
        记录首个差异位置与逐层相对误差
    end if
end for
$\rho \leftarrow c_{\text{diff}} / N$
if $\rho \leq \tau$ 且逐层相对误差均不超过 $\epsilon_{\max}$ **then**
    return $\{$验证通过$, c_{\text{pass}}, c_{\text{diff}}, \rho\}$
else
    return $\{$验证失败$, c_{\text{pass}}, c_{\text{diff}}, \rho,$ 差异日志$\}$
end if

2.3.3 统一调度接入机制

切分调度与协变混淆并非两个独立模块，而是接入同一条执行路径。算法 3 给出模块选择流程：同一份策略 $\mathcal{P}$ 下发后，系统依据运行角色与当前混淆配置，自动决定加载明文推理模块还是混淆推理模块；边端在密钥缺失时直接拒绝创建混淆相关模块，通过强制密钥校验防止安全机制被绕过。

算法 3 动态策略下的推理模块选择算法

输入： 调度策略 $\mathcal{P}$，运行角色 $r \in \{\text{edge}, \text{cloud}\}$；模型类型 m，部署配置 E

输出： 运行时推理模块 A

解析 $\mathcal{P}$ 得到层级切分向量与角色执行计划
if 服务端混淆检查点已在 E 中配置 **then**
    if $r = \text{edge}$ **then**
        if 客户端密钥未在 E 中配置 **then**
            拒绝创建混淆推理模块　　▷ 强制密钥校验，防止绕过安全机制
        end if
        $A \leftarrow$ 边端混淆预填充模块（加载混淆检查点 + 客户端密钥）
    else
        $A \leftarrow$ 云端混淆解码模块（仅加载混淆检查点，不持有密钥）
    end if
else
    $A \leftarrow$ 明文推理模块
end if
将 $\mathcal{P}$ 绑定至 A 并启动运行时
return A

从调度策略生成到混淆推理的端到端流程可概括为：调度器按实时资源生成策略 $\mathcal{P}$ 并下发；系统完成密钥校验与混淆模块初始化；边端执行词表置换 $x' = \pi(x)$ 与预填充；云端在混淆模型 F' 上解码并输出混淆词元 y'；边端聚合器经 π^{-1} 逆置换与 Detokenizer 恢复明文；整个过程资源调度与隐私保护被绑定在同一条可追踪、可观察链路上。

2.4 平台实现与运行流程

2.4.1 系统架构

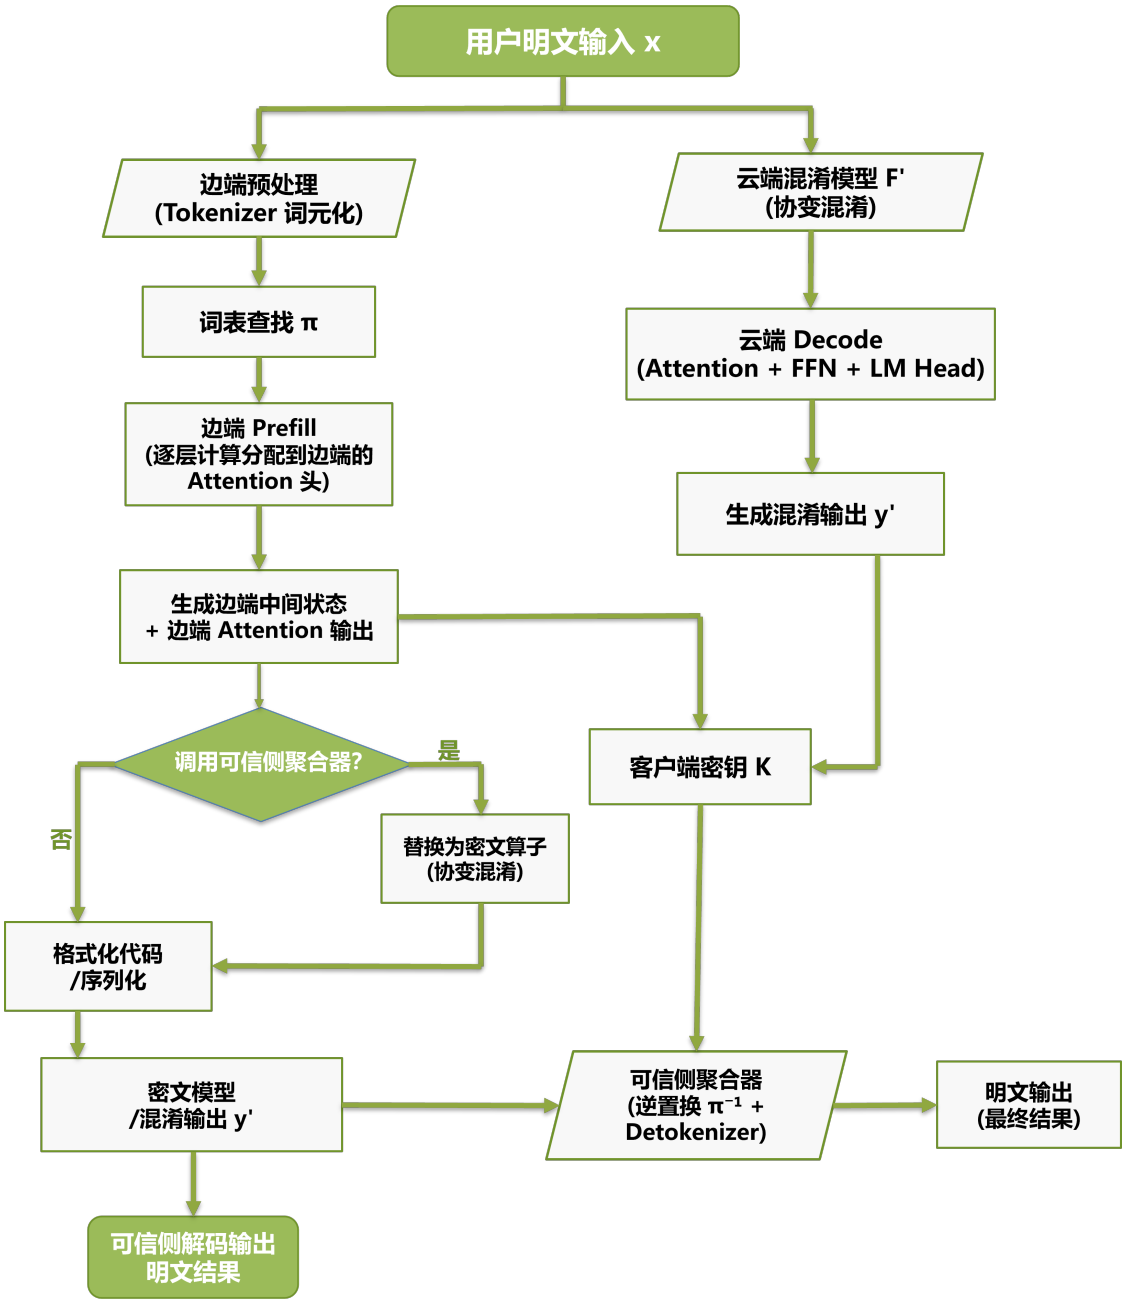


图 2.2　协变混淆推理端到端流程

图 2.2 已给出 PrivLLM 系统的整体流程，下面进一步说明五类核心模块的协作关系；这些模块通过 HTTP/JSON 协议调度、gRPC 流式传输数据，形成可追踪、可复核的推理链路。

（1）边端交互模块。基于 OpenWebUI 二次开发，提供登录鉴权、模型选择、会

话初始化、推理触发与结果展示功能；界面以“边端明文恢复视图”与“云端混淆词元视图”双栏对照呈现，直观展示“边端可读、云端仅见混淆”的隐私边界。

（2）协变混淆变换模块。离线阶段依据式 (2.13) 生成变换参数集合 K，按嵌入层、逐解码层与输出头的局部协变关系将明文权重导出为混淆权重；导出后调用算法 2 在验证样本集上做词元级等价性验证，确认混淆模型在当前硬件与数值精度下满足协变约束后才发布检查点。客户端密钥（π 与 π^{-1}）仅交付边端，混淆检查点交付云端。

（3）云端调度与监控模块。采集边端与云端资源状态、网络时延与模型负载，调用算法 1 产出层级切分策略 $\mathcal{P}$ 并通过 HTTP/JSON 下发；同时基于 Grafana 维护覆盖边端 GPU、云端 GPU 与昇腾 NPU 的资源监控面板，记录处理器利用率、显存占用、网络吞吐与 NPU 温度等运行参数。

（4）边云切分运行时模块。在边端与云端分别部署，依据策略 $\mathcal{P}$ 加载对应模型分片；根据运行角色与混淆配置，自动选择加载明文推理模块或混淆推理模块，将切分策略直接映射为具体的推理执行路径。

（5）边端聚合模块。接收云端返回的混淆输出片段，利用逆置换 π^{-1} 逐词元恢复，再经 Detokenizer 还原为自然语言文本；同时执行完整性校验与安全审计，保留混淆词元字段用于对照与评估。

2.4.2 系统运行流程与页面展示

为验证平台可落地性，本作品在真实边云硬件上完成端到端部署，并保留关键运行截图作为证据。下面按典型使用流程展示主要页面。

（1）边端登录与模型选择。边端交互界面基于 OpenWebUI 二次开发。用户通过浏览器进入系统后首先完成登录，进入主界面后可在模型选择控件中选取本次推理所用模型（图 2.4），系统完成环境检查后进入会话就绪状态。

（2）切分策略与加载。用户发起请求后，调度模块依据边云资源与网络状态生成层级切分策略，并驱动边云运行时加载相应模型分片（图 2.3）。图 2.5 进一步给出按层级的切分详情：页面以不同颜色标识每个注意力头与 FFN 的执行位置，在图示实例策略下边端承担约 23% 注意力头、云端承担约 77%，FFN 全部部署于云端。

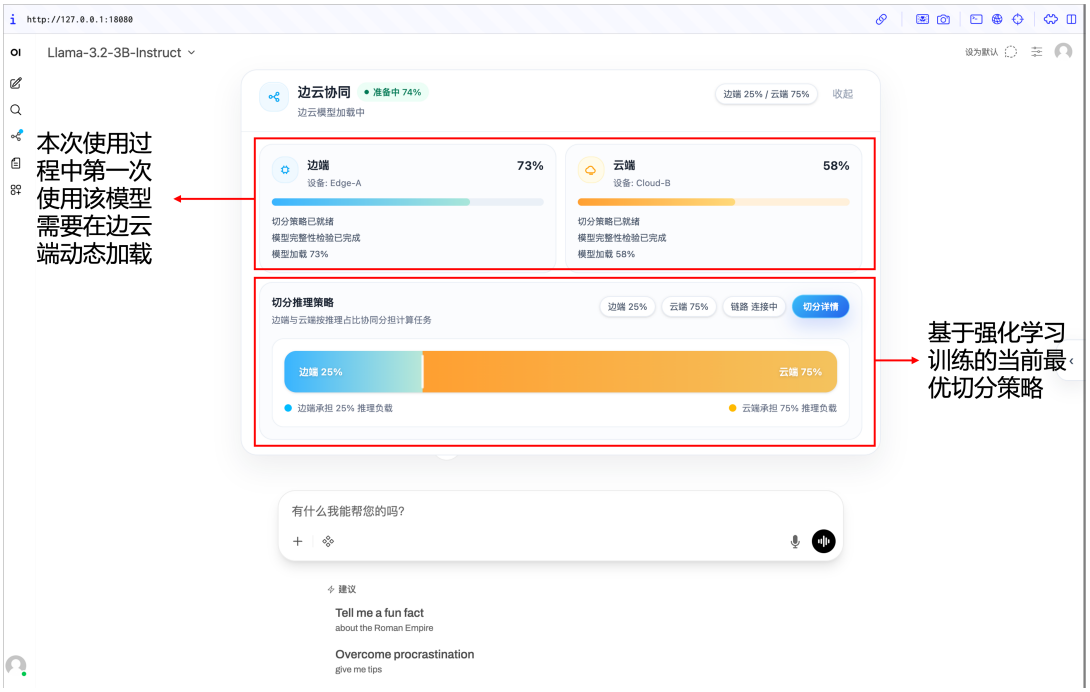


图 2.3　模型切分与加载示意图

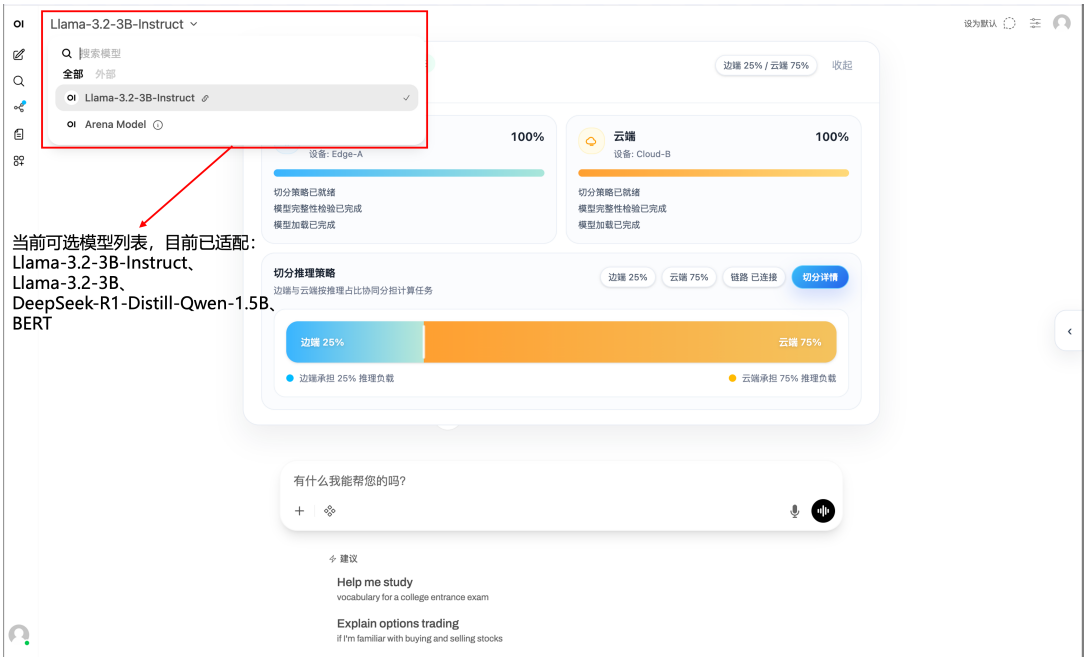


图 2.4　模型选择与会话就绪页面

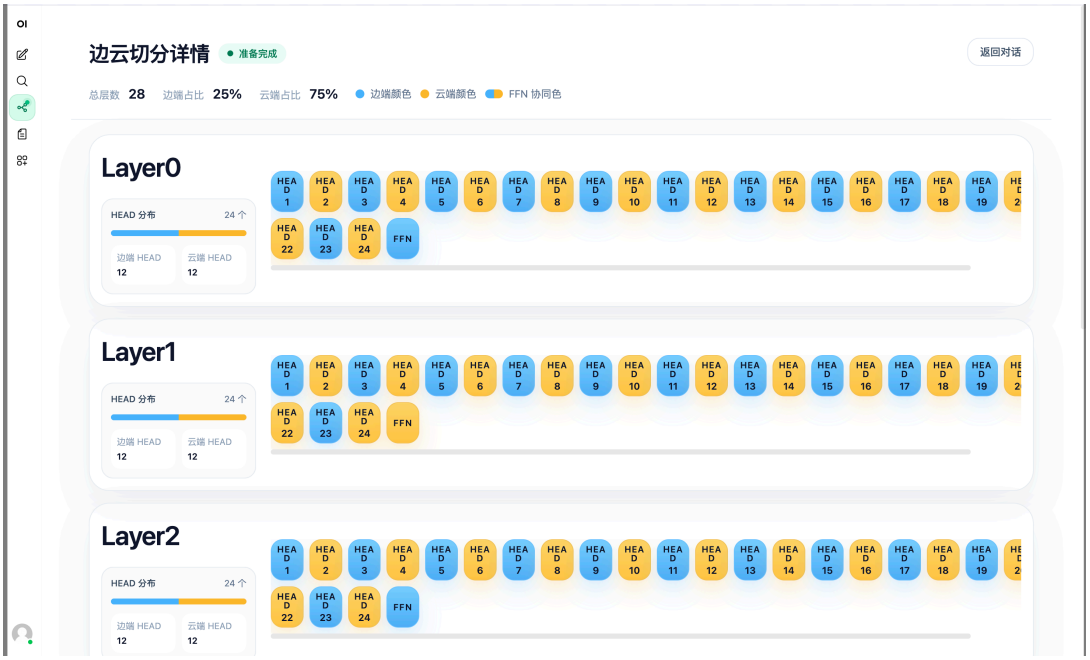


图 2.5　层级注意力头与 FFN 切分详情

（3）混淆推理明密文对照。加载完成后，用户输入提示即可触发边云协同混淆推理。图 2.6 给出推理响应的双栏对照视图：左侧的明文视图呈现边端恢复后的自然语言回答，右侧的混淆视角呈现云端全程所见的混淆词元序列，二者按词元一一对应，直观呈现“云端仅见混淆词元、明文语义仅在边端恢复”的隐私边界。



图 2.6　推理响应的明文恢复与云端混淆词元对照视图

（4）系统资源监控。平台部署覆盖边云各节点的资源监控。图 2.7 与图 2.8 分别

为边端 GPU 与云端 GPU 节点的监控页面，涵盖显存、处理器利用率、内存使用率与网络吞吐等指标；图 2.9 为昇腾 910B4-1 节点监控，包含 NPU 温度、NPU 显存、CPU 使用率与网络吞吐等指标。



图 2.7　边端 GPU 节点资源监控



图 2.8　云端 GPU 节点资源监控

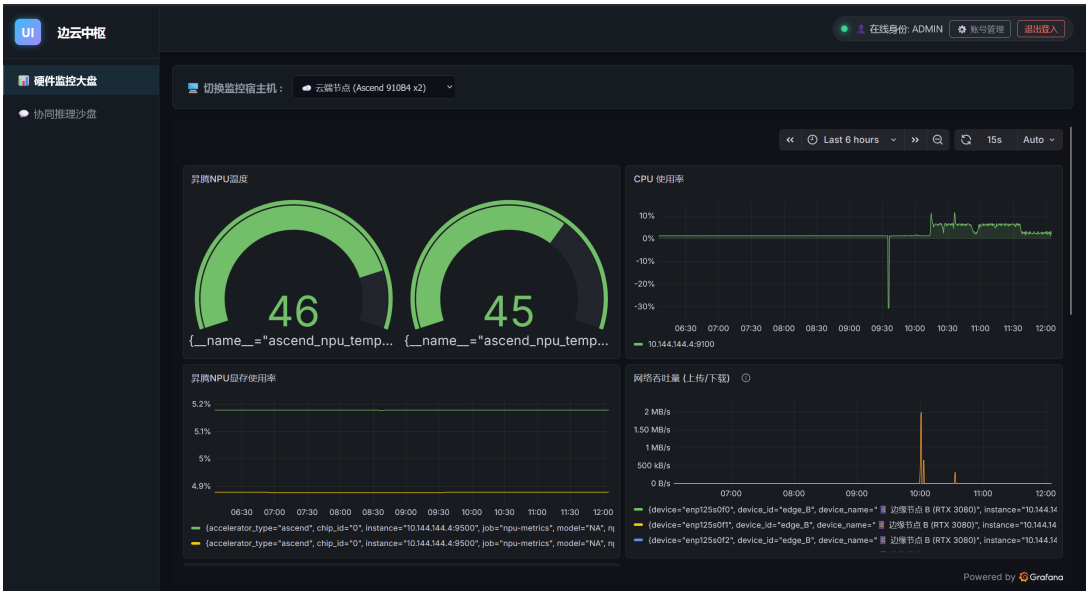


图 2.9　昇腾 910B4-1 节点运行监控页面

2.4.3 国产加速平台适配

在政务、工业与关键信息基础设施场景中，推理系统需支撑自主可控软硬件环境。华为昇腾生态通过 CANN、MindIE、ATB Models 与 torch_npu 等组件支持模型推理[31-32]。PrivLLM 将边云协同运行时与协变混淆推理链路迁移至昇腾平台，统一推理入口、边端聚合器、预填充节点与解码节点在国产 NPU 上保持与通用 GPU 一致的执行逻辑。图 2.9 为昇腾 910B4-1 节点运行监控页面，相关性能评估见 3.4 节。

第三章 作品测试与分析

3.1 测试方案

3.1.1 测试目标与环境

本章从平台功能、切分调度、推理性能、混淆安全性与国产化适配五个维度评估 PrivLLM 的实际表现。

实验环境由两台异构服务器构成边云协同节点。**云端服务器**配备 NVIDIA RTX 5090 GPU 与昇腾 Ascend 910B4-1 NPU，操作系统为 Ubuntu 22.04，承担混淆模型解码与全局调度任务；**边端服务器**配备 NVIDIA RTX 4090 GPU，操作系统为 Ubuntu 22.04，承担词元置换与预填充计算。两端通过千兆以太网互联，调度层采用 HTTP/JSON 协议，推理数据面采用 gRPC 流式传输。

平台核心运行时与协变混淆变换均使用 Python 实现。词表置换在全词表上构造为均匀随机双射，参数变换通过隐藏维度置换与可逆缩放矩阵组合构造，具体细节见 2.3.2 节。被测大模型为 Llama-3.2-3B-Instruct，包含 28 层 Transformer 解码器、每层 24 个注意力头与 8 个键值头（GQA）[39]，隐藏维度为 3072，上下文窗口最大为 4096 词元。

3.1.2 评估维度与样本规模

评估从以下三个维度展开，与 3.1.1 节提出的五个维度形成对应：

1. **平台功能维度**：验证边端交互入口、云端调度器、边云运行时、资源监控面板与边端聚合器能否形成端到端闭环，验证典型用户操作流程（登录、选模、切分加载、混淆推理、监控查看）的可用性；
2. **系统性能维度**：在 900 条真实请求压测下评估协变混淆链路的端到端延迟、首词元延迟、解码吞吐与明文切分/单机基线的差异，并通过带宽限速、并发与长上下文扩展测试刻画系统鲁棒性；在昇腾 910B4-1 上额外完成 500 条请求压测以验证国产化适配；
3. **混淆安全维度**：在真实边云链路上采集 1100 条提示，覆盖 6 类场景，共 52575 个对齐的明文–混淆词元对，按 L1 唯密文观察与 L2 元数据利用两类云端真实能力组织多组安全评估实验，从内容保护、置换性质与元数据侧信道三个角度系统刻画云端可观察数据范围的安全边界，样本分布概览如图 3.1 所示。

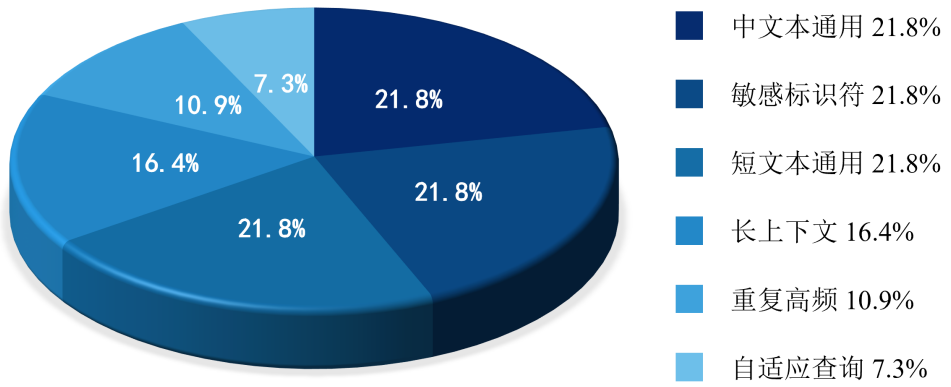


图 3.1　样本分布概览

本章对比基准统一为以下三条链路：

- **单机**：1×GPU 本地推理，无网络跳转，代表“纯边端/纯本地”上限；
- **明文切分**：edge+cloud 两端协同推理，不启用协变混淆，代表“无隐私保护的边云协同”基线；
- **协变混淆切分**：edge+cloud 两端协同推理并启用协变混淆，即 PrivLLM 的完整链路。

3.2 平台功能与运行流程测试

本节从用户视角验证平台交互功能能否端到端贯通，覆盖登录鉴权、模型选择、切分策略下发与加载、混淆推理双栏展示、资源监控与国产化平台运行六个关键环节。

（1）边端登录与模型选择。用户通过浏览器进入平台后完成登录，可在模型选择控件中选取本次推理所用的 Llama-3.2-3B-Instruct 大模型；系统完成环境检查与服务就绪探测后进入会话就绪状态。

（2）切分策略下发与加载闭环。用户发起请求后，云端调度器依据实时资源状态生成层级切分策略，并通过统一调度层下发至边端与云端运行时；运行时依据算法 3 创建协变混淆推理模块并完成模型分片加载，两端通过就绪回调向调度器报告加载完成。多次重复触发均成功进入“已完成”终态，运行时一致性校验显示协变混淆结构、服务端参数摘要与切分策略摘要在边云两端一致——说明真实调度策略已被加载至混淆运行时。

（3）混淆推理明密文对照展示。推理界面左侧呈现边端逆置换恢复后的自然语言回答，右侧呈现云端所见混淆词元序列，二者按词元一一对应。该双栏视图直观展示

“边端可读、云端仅见混淆词元”的隐私边界，也为后续安全评估提供人工审计入口。

（4）资源监控面板。平台部署基于 Grafana 的资源监控系统，覆盖边端 GPU 节点、云端 GPU 节点与昇腾 NPU 节点，核心指标包括处理器利用率、显存占用、内存使用率、网络上下行吞吐与显卡温度，为运行状态复核与问题定位提供可视化依据。

（5）国产化平台运行。在昇腾 910B4-1 服务器（Kunpeng-920 CPU，96 逻辑核，124 GiB 内存，CANN 8.3.0.1.200，驱动 25.2.3，PyTorch 2.7.1 + torch_npu 4.57.1）上，平台的统一推理入口、协调聚合层、预填充节点与解码节点均正确执行，昇腾 NPU 节点的监控指标可正常采集，详见 3.4 节。

综上，平台已完成“前端发起 → 调度生成 → 运行时加载 → 混淆推理 → 边端恢复 → 监控复核”的全链路闭环，各功能模块在真实边云硬件上可交互、可观测、可复核。

3.3 边云协同切分机制调度策略评估

3.3.1 实例策略统计

动态切分策略由调度器依据边端显存上限、云端设备状态、资源利用率与任务条件按算法 1 实时生成，因此不同部署环境、设备组合或负载下边云比例可以不同。在本测试环境中，调度器为 28 层 Llama-3.2-3B 解码器返回的实例策略统计见表 3.1。

表 3.1　动态切分实例策略统计

指标	数值	说明
模型规模	Llama-3.2-3B	28 层 Transformer 解码器
注意力头总数	672	28 层 × 24 头
边端注意力头数	157	占比 23.36%
云端注意力头数	515	占比 76.64%
边端 FFN 模块数	0	不在边端执行
云端 FFN 模块数	28	占比 100%

实例策略将计算密集、参数量大的 FFN 全部放至云端，边端保留约 23% 的注意力头与词元置换工作，与“边端显存充裕、网络往返时延较低、云端负载适中”条件下算法 1 的预期输出一致。

3.3.2 资源扰动下的策略响应

为进一步验证强化学习策略对环境变化的响应能力，本节在三组资源扰动条件下对训练完成的策略网络进行离线复算，结果见表 3.2。

表 3.2　资源扰动条件下的切分策略复算

资源条件	边端头数	云端头数	边端占比	云端占比
基准状态	157	515	23.36%	76.64%
边端显存紧张	96	576	14.29%	85.71%
网络延迟升高	224	448	33.33%	66.67%
云端负载升高	252	420	37.50%	62.50%

复算结果显示：当边端显存收紧时，h_{mem} 硬上限将边端头数压至 96；当网络延迟升高时，策略网络推动边端承担更多注意力头以降低跨边云通信开销；当云端负载升高时，更多头被迁回边端以缓解云端压力。这验证了强化学习策略网络的资源响应能力——切分策略不是静态配置，而是对实时资源状态的自适应决策。

3.4 隐私保护大模型推理性能评估

3.4.1 协变混淆链路性能与基线对比

为在足够大样本下可靠刻画系统性能，本节使用 Llama-3.2-3B-Instruct 在协变混淆链路上发起 **900 条**提示请求，按提示长度划分为短、中、长三档，对应约 10、33、78 词元，每档各 300 条；每条请求设置温度为 0、最大生成长度 64 词元，记录客户端端到端延迟、首词元延迟（Time To First Token, TTFT）、边端/云端预填充时间、解码时间与解码吞吐。900 条请求全部成功完成。表 3.3 给出分档统计结果。

表 3.3　协变混淆链路推理性能

提示长度	完成率	端到端延迟 (s)	首词元延迟 (s)	边端预填充 (ms)	云端预填充 (ms)	解码 (ms)	吞吐 (词元/s)
短	300/300	3.006	2.481	17.6	1540.8	524.3	121.98
中	300/300	4.875	4.349	20.4	3405.9	524.6	122.04
长	300/300	8.431	7.901	21.4	6955.9	529.0	121.03
总体	**900/900**	**5.437**	**4.910**	—	—	526.0	**121.68**

提示长度从短增长至长时，首词元延迟由 2.481 s 增长至 7.901 s，主要由云端预填充时间随提示长度从 1540.8 ms 线性增长至 6955.9 ms 造成，而该增长主要受 VPN 链路上嵌入传输时间的影响；三档提示的**解码吞吐稳定在 121–122 词元/s 区间**，说明 GPU 稳态解码阶段对提示长度不敏感。

为量化协变混淆本身引入的性能开销，表 3.4 给出同台效率阶梯对比，涵盖单机、明文切分与协变混淆切分三条链路，各 900 条。

表 3.4　不同推理链路效率对比

链路	成功率	端到端均值 (s)	首词元均值 (s)	解码 (ms)	吞吐 (词元/s)
单机	100%	0.469	0.010	458.5	134.05
明文切分	100%	4.614	4.088	524.9	121.89
协变混淆切分	100%	5.437	4.910	526.0	**121.68**

对比可见：

1. 单机无网络跳转，TTFT 仅 10 ms、端到端延迟 0.469 s、吞吐 134.05 词元/s，代表本地化推理的性能上限；
2. 切分后引入边云通信，TTFT 主要由 VPN 链路传输时间决定，端到端延迟与吞吐均出现相应变化；
3. **协变混淆切分与明文切分在稳态解码吞吐上基本持平，二者分别为 121.68 与 121.89 词元/s，相对差异约** 0.17%，**落在测量噪声范围内**，说明协变混淆的词表置换与参

数变换基本不引入额外 GPU 计算开销。

需要说明：以稳态解码吞吐作为混淆额外开销的判断依据更为可靠。以明文切分吞吐 121.89 词元/s 为基线，协变混淆链路的性能损耗约为 **0.17%**，在实验范围内未观察到明显性能退化。

3.4.2 带宽敏感性

为刻画边云链路带宽对性能的影响，使用 Linux tc HTB 对混淆链路进行限速测试，结果见表 3.5。

表 3.5　tc HTB 链路限速对混淆切分链路的影响

带宽条件（Mbps）	成功率	端到端均值 (s)	首词元均值 (s)	吞吐 (词元/s)
∼57	100%	4.182	3.655	121.73
40	100%	5.981	5.450	121.65
20	100%	7.431	6.902	121.37
10	91.67%	11.769	11.242	121.88

在 10–57 Mbit/s 区间内，**解码吞吐始终稳定在 121–122 词元/s**，带宽仅影响首词元延迟。这印证了协变混淆词表置换不改变词元标识的位宽，系统延迟完全由边云链路带宽决定、而非混淆计算；10 Mbit/s 下出现的少量超时源于网络排队过长导致的客户端超时设置，与混淆计算无关。

3.4.3 并发鲁棒性与长上下文扩展

图 3.2 给出 1/2/4/8 路并发流式请求下的表现。四个并发档位下请求成功率均为 100%，聚合吞吐从 81.22 词元/s 提升至 104.73 词元/s，说明服务端解码资源在多请求场景下得到更充分利用，平台在并发负载下保持稳定。

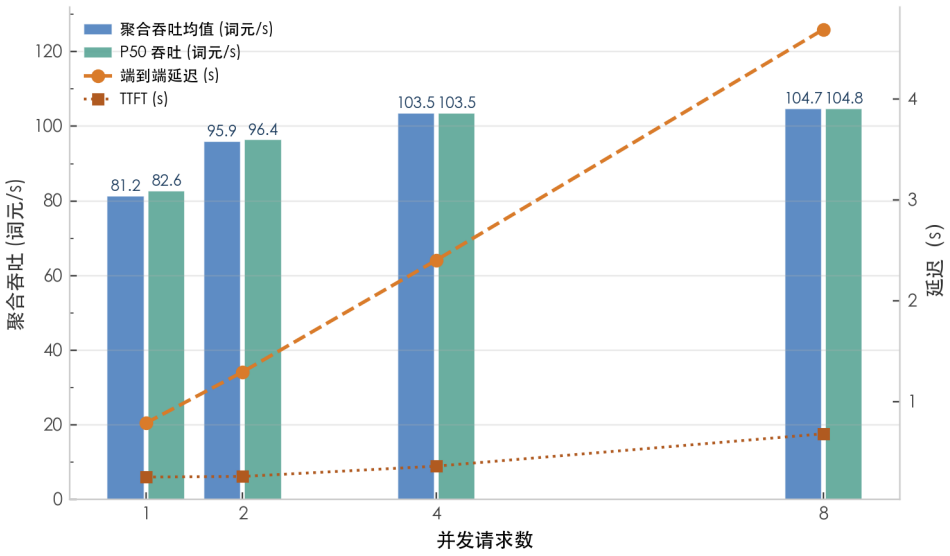


图 3.2　并发扩展测试结果

长上下文扩展测试在 87–912 词元输入区间内构造五档提示、每档 3 次请求，输出长度固定为 48 词元。如图 3.3 所示，15 次请求均产生非空流式输出；随输入长度增加，首词元延迟主要由云端预填充时间增长驱动，解码吞吐从 118.66 词元/s 下降至 93.25 词元/s，但始终保持稳定返回，未出现崩溃或异常终止。

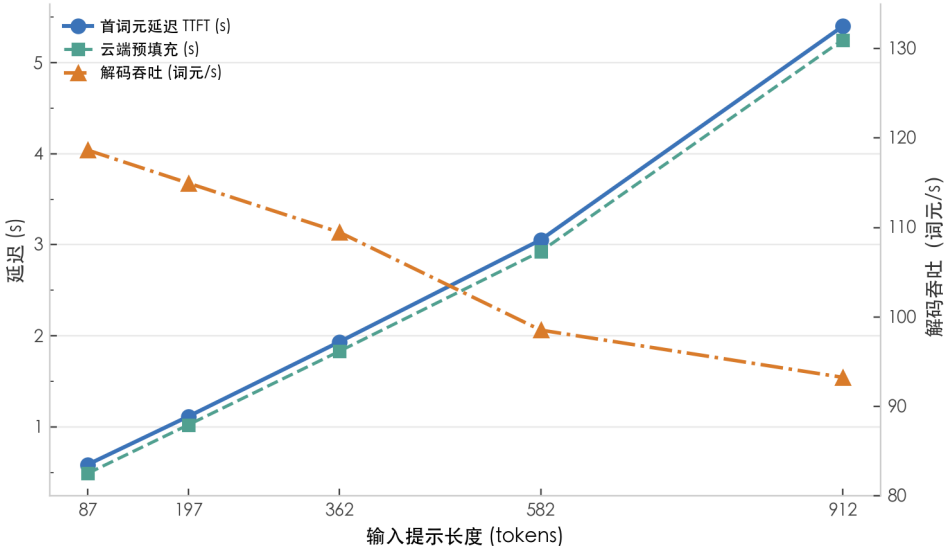


图 3.3　长上下文扩展测试结果

国产加速平台适配。国产加速平台适配测试在配备 2 张昇腾 Ascend 910B4-1 NPU 的服务器上完成，详见 3.1 节环境描述，被测模型同样为 Llama-3.2-3B-Instruct，请求入口为 OpenAI 兼容协议，推理路径依次经过协调聚合层、预填充节点与解码节点。表 3.6 给出 500 条请求压测结果。

表 3.6　昇腾 910B4-1 平台推理性能

指标	结果
成功请求数	500 / 500
输出吞吐	2.51 词元/s
总吞吐	56.42 词元/s
请求吞吐	1.25 请求/s
平均延迟	0.80 s
P50 延迟	0.73 s
P95 延迟	0.75 s
最大延迟	32.50 s

昇腾平台上 500 条请求全部成功完成，P95 延迟 0.75 s，总吞吐 56.42 词元/s。平台统一推理入口、协调聚合层、预填充与解码运行时均在昇腾平台上正确执行，结合覆盖昇腾 NPU 的监控记录（图 2.9），验证了 PrivLLM 在通用 GPU 与国产 NPU 双平台上的兼容能力。

3.5 混淆数据安全评估

协变混淆的核心安全目标是：在云端参与推理的前提下，使其无法还原用户原始输入与输出内容。需要明确：协变混淆并非密码学意义上的加密算法，而是一种保持计算等价性的可逆表示变换；其安全性来源于词表置换 π 与隐藏维度变换 S 这两个客户端密钥对不可信侧的保密性，其安全地位与对称密码体制中“私钥/密钥必须保密”的前提同质。在不知道 π 的前提下，云端面对的是经 π 置换后的混淆词元流，等价于唯密文攻击场景，对 $V = 128256$ 个词元的全局均匀随机置换进行暴力还原的搜索空间高达 128256!，在计算上不可行。

为系统刻画云端可见数据范围的安全边界，本节按攻击者能力由弱到强划分为 L1 与 L2 两个层级，据此组织多组安全评估实验，见表 3.7。L1/L2 是恶意云端在客户端密钥未泄漏时真实具备的能力，构成本节主要评估对象。

表 3.7　攻击者能力分层与对应实验

层级	攻击者能力	对应实验	现实可能性
L1 唯密文观察	仅观察混淆词元的标识、表面文本与时序	混淆词元直读、敏感标识符、频率匹配、长度侧信道	高
L2 元数据利用	进一步利用提示长度、请求频率与时延模式	侧信道分类、多请求关联、时延漂移	高

本轮评估在真实边云链路上采集 1100 条提示，覆盖 6 类场景，共 52575 个对齐的明文–混淆词元对，所有数据均来自真实运行产物。

3.5.1 L1：唯密文攻击下的内容保护

本节评估恶意云端仅观察混淆词元流（L1）时能否还原实际内容。我们设计四类攻击：混淆词元直读检验混淆词元表面是否泄漏明文；敏感标识符检验结构化隐私字段是否原样出现；频率匹配检验经典代换密码频率分析是否奏效；长度侧信道检验词元表面长度是否泄漏明文长度。结果汇总于表 3.8。

表 3.8　唯密文攻击实验结果

攻击类型	样本量	关键指标	实测值
混淆词元直读	52575 词元对	严格相等率	0.00%
		字符 Jaccard	0.009
敏感标识符	240 句 × 8 类	精确命中	0/240
		格式正则命中	0/240
频率匹配	38592 词元	top-1 复原率	$\leq$ 1.6%
		去重词表 top-1	$\leq$ 0.15%
长度侧信道	52548 词元对	明–混词元表面长度 Pearson 相关	0.083

混淆词元直读。 52575 个对齐词元对中，混淆词元与明文表面严格相等率为 0.00%，即不存在任何一个词元的混淆形式恰好等于其明文；规范化空白字符后相

等率仅 0.030%，平均字符级 Jaccard 相似度仅 0.009。这说明经全局随机置换后，原始词元被映射到语义无关的词元表面，云端读到的是语义上无连贯意义的混淆序列。

敏感标识符。构造手机号、邮箱、证件号、银行卡号、API 密钥、设备号、地址与随机串共 8 类敏感标识符，每类 30 句、合计 240 句查询，检查混淆提示与混淆输出中是否原样出现敏感串或命中相应格式正则。结果显示精确命中与格式正则命中均为 0/240，对应 0.00% 泄漏率；零泄漏的 Wilson 95% 单侧上界约 1.53%。原因在于协变混淆在词元标识层置换，敏感串的每个组成词元被独立映射为无关词元——即使攻击者已知“银行卡号为 16 位数字”这类格式规则，数字词元已被替换为非数字词元，无法从混淆序列中检出。

频率匹配。模拟三档攻击者——零知识（均匀先验）、领域感知（通用中文词频）与分布感知（边云协同领域词频），对 38592 个混淆词元尝试词频对齐。即使最强的分布感知攻击者，单词元 top-1 复原率仅 1.575%，去重词表 top-1 复原率更低至 0.146%；在 52575 个词元规模的语料上，稀疏离散的命中无法构成连贯语义——经典频率分析对协变混淆不成立。

长度侧信道。混淆词元表面长度与明文词元表面长度的 Pearson 相关系数仅 0.083，相关性接近于零。原因是置换发生在词元标识空间：一个 1 字符中文词元可能被映射到一个 7 字符英文词元，词元表面长度在置换前后基本脱钩。

表 3.9　词表置换的密码学性质验证

验证内容	实测值
词元级确定性	99.90%（2047/2049）
位置无关性	49/50 位置不变
跨会话稳定性	160/160 字节级匹配

为支撑上述安全结论，表 3.9 验证词表置换 π 的确定性、位置无关性与跨会话稳定性三项性质。

在 52548 个真实词元对中，99.90%（2047/2049）的明文词元表面映射到唯一混淆词元表面，仅有的两个例外是 Unicode 替换字符 U+FFFD，这是中文字节拆分时产生的分词副产物，并非真实自然语言词元；真实词元层面 π 是 100% 确定的查找表。位置无关性测试对 top-50 高频明文词元，检查其在 5 个位置区间的混淆结果是否一致，结果 49/50 位置不变，唯一例外仍是上述分词副产物。跨会话稳定性测试在完整卸载并重启会话前后重放同 5 条提示，160 个词元的混淆结果 100% 字节级一致，与

客户端密钥是静态文件的性质相符。确定性是置换密码的固有特征：在 L1/L2 唯密文场景下，攻击者无从得知映射关系，确定性不构成额外安全风险；一旦客户端密钥泄漏（已超出本节威胁模型），确定性将使攻击者字典可跨会话累积，此时密钥轮换即为限制损害的纵深防御手段。

3.5.2 L2：元数据侧信道与多请求关联

即便无法还原内容，恶意云端仍可能利用可见元数据进行粗粒度推断。表 3.10 给出云端真正可观测特征的侧信道强度。

表 3.10　元数据侧信道强度评估

云端可观测特征	分类准确率
混淆词元数	26.4%
混淆词元表面总长度	29.7%
混淆词元表面长度方差	30.0%
时延（L2，网络层）	65.1%

三类混淆内容元数据特征分类准确率均略高于 21.8% 的多数类基线，但远低于能支持有效内容推断所需的强度，攻击者至多获得粗粒度请求类别。协变混淆后明文字符数与边端预填充时延均不进入通信信道，不构成云端可观测侧信道。准确率为 65.1% 的时延侧信道源于边端预填充计算量随提示内容变化导致的端到端时延分布；跨时段重测显示绝对时延受系统负载影响漂移，均值由 5.20 s 变为 2.47 s，但请求间相对次序仍保留 0.698 的 Pearson 相关——该侧信道具结构性，可在协调层通过固定窗口时延填充与解码速率归一化缓解。

多请求关联方面，由于 π 是确定性映射，高频词元在所有请求中产生相同混淆标识，使得讨论同一主题的请求在混淆词元集合上重叠更多。实测同类请求对平均 Jaccard 相似度为 0.118、跨类为 0.059，二者相差约 2 倍——与明文基线中同类/跨类比值 1.73× 的水平相当，不引入额外关联信号；该侧信道仅支持粗粒度主题关联，不等于内容还原，可通过按会话派生盐值或填充词元进一步缓解。

密文信息熵方面，混淆词元流 Shannon 熵为 8.58 bits/token，明文为 8.61 bits/token，差值仅 0.03 bits，相对差异不足 0.4%。混淆序列熵未显著降低，攻击者无法通过熵减推断信息。

3.5.3 跨方案安全风险对比

为系统梳理协变混淆路线相对其他安全推理方案的安全风险差异，表 3.11 从频率分析、元数据侧信道、多请求关联与密文信息熵四个维度，对基于 MPC 的 CipherGPT/BumbleBee/BOLT、基于 TEE 的 PipeLLM、基于静态协变混淆的轻量表示变换方案与 PrivLLM 进行对比。需要说明的是，表中 MPC/TEE 方案的数据并非在本平台实测，而是基于其机制特点的保守估计：同一模型同一提示下生成词元数相同，故存在词元数侧信道；词元表面在密态共享或 enclave 隔离下不可见，因此词元表面侧信道对其标注为“不适用”。静态协变混淆方案缺少运行时完整性校验，若被以概率 p 旁路则隐私退化率为 $p \cdot 100\% + (1-p) \cdot 1.6\%$；本平台通过算法 3 的边端强密钥校验将 p 锁定为 0。

表 3.11　跨方案安全风险定量对比

方案	TFMA top-1	词元数侧信道	词元表面侧信道
CipherGPT / BumbleBee / BOLT	不适用	≈26%	不适用
PipeLLM（TEE）	不适用	≈26%	不适用
AloePri（静态协变混淆）	≤ 1.6%	≈26%	≈29%
PrivLLM	**≤ 1.6%**	**26.4%**	**29.7%**
随机基线	—	16.7%	16.7%

3.6 方案对比

为全面评估 PrivLLM 在效率、安全与部署三个维度的综合定位，表 3.12 从 6 个关键维度出发，将本平台与 6 类代表性方案横向对比。

表 3.12　PrivLLM 与代表性安全推理方案的多维度对比

方案	威胁模型	技术路线	推理时延	模型支持
CipherGPT	2PC 半诚实	MPC+HE	分钟级/词元	GPT-2
BumbleBee	2PC 半诚实	MPC+FSS	秒级/词元	Transformer
BOLT	2PC 半诚实	MPC+FSS	秒级/词元	GPT/BERT
PipeLLM	TEE 隔离	TEE	接近明文	通用 LLM
AloePri	云端半诚实	协变混淆	接近明文	Llama
PrivLLM	云端半诚实 可信边端	协变混淆、 切分与调度	5.4 s 端到端 121.68 词元/s	Llama-3.2-3B DeepSeek-R1-Distill-Qwen-1.5B BERT

方案	边云协同	系统化程度	国产化适配
CipherGPT	×	协议实现	×
BumbleBee	×	协议实现	×
BOLT	×	协议实现	×
PipeLLM	×	运行时	×
AloePri	×	变换工具	×
PrivLLM	✓	端到端闭环 运行时密钥校验	✓

由表可见本平台在以下四个维度具备差异化定位：

1. **相对 MPC/HE 路线（CipherGPT/BumbleBee/BOLT）**：本平台不以严格密态计算语义为目标，而是以可用性、秒级端到端延迟与现有 LMaaS 基础设施兼容性作为主要取舍。MPC 方案通常需要数量级更高的通信与计算成本；本平台在 900 条真实请求下取得 121.68 词元/s 解码吞吐（与明文切分基线 121.89 词元/s 基本持平），且在 52575 个词元对上实现混淆词元直读 0.00%、敏感标识符零泄漏，兼顾在线可用性与内容保护能力。

2. **相对 TEE 路线（PipeLLM）**：本平台不依赖特定可信硬件，部署灵活性更强，且已在通用 GPU 与昇腾 910B4-1 双平台完成端到端实测，昇腾 500 条请求全部成功，P95 延迟 0.75 s。
3. **相对静态协变混淆方案**：本平台增量在于将协变混淆从模型导出阶段的静态变换扩展为动态调度可触发的运行时机制，并以真实调度闭环与运行时密钥校验保证安全路径不被窃听，补齐了系统层面的关键一环。
4. **边云协同维度**是上述对比方案均不具备的差异化能力——对比方案普遍假设纯云端推理架构，本平台通过边云注意力头级细粒度切分同时利用边端隐私隔离与云端算力，并在资源感知调度下弹性调整分工，在隐私敏感且算力不对称的场景中形成区别于纯云端方案的系统路线。

第四章 创新性说明

为应对边云协同大模型推理中算力不足、网络开销与隐私暴露相互牵制的问题，PrivLLM 提出一套将资源感知切分、协变混淆隐私推理与统一调度接入协同整合的工程方案，突破了现有方法难以兼顾推理高效性与安全性、算力资源利用不充分、国产化适配困难等局限，推动隐私保护大模型推理的工程化落地。以下对三个创新点逐一说明。

4.1 资源感知细粒度大模型切分机制

现有边云协同推理工作普遍以“整层迁移”为主要切分粒度，难以匹配 Transformer 解码器内部计算量相对分散、可并行的多头注意力与参数量和计算量都更大的前馈网络之间的结构差异；同时切分决策往往忽略边端显存硬约束，在真实异构硬件上易出现显存溢出或调度失效。针对这一问题，本作品将切分粒度细化至“层–注意力头–FFN 子模块”三级，并把显存硬上限显式纳入策略生成公式，使调度决策能够同时适应 Transformer 内部算子特征与边端资源边界。

更细的切分粒度带来了更灵活的边云分工：同一层内可将计算密集、参数量大的 FFN 子模块全部分配至云端，同时保留部分注意力头在边端执行，从而在异构资源条件下更充分地利用两端算力；相比整层迁移，注意力头级切分提供了更丰富的决策自由度。策略生成算法（算法 1）把边端可用显存、队列长度与负载状态编码进状态，并通过式 2.3 中的容量风险项 $C_e(s,a)$ 在奖励函数里惩罚超出边端算力或存储预算的动作；策略网络对每一层的每个注意力头和 FFN 分别给出位置决策，在线推理时只需一次前向传播即可解码为运行时可执行的层级切分策略，实现“边端能力不超限的前提下随网络与负载弹性调整”。层级切分策略向量 $\mathcal{P}$ 以结构化格式在调度后端与边云运行时之间传递，便于在不同硬件、网络与模型规模下替换具体调度算法，例如未来引入更复杂的启发式或学习型调度器，而不必改动运行时加载逻辑。

该切分机制在 Llama-3.2-3B 实测中实例化为 76.64% 云端注意力头、100% 云端 FFN 的策略，并在边端显存紧张、网络延迟升高与云端负载升高三组扰动复算中按预期方向调整；协变混淆链路在 900 条请求压测下取得 121.68 词元/s 的解码吞吐，验证了该切分机制在真实硬件上的有效性。

4.2 基于协变混淆的隐私保护推理方案

在隐私保护层面，本作品针对现有方案要么密码学开销过高、要么简单扰动安全性不足这一两难，设计并实现了基于词表置换与协同可逆参数变换的协变混淆推理链路。与已有静态协变混淆原型相比，本作品面向现代 LLM 的完整组件给出系统化

协变处理，并将其接入边云协同推理运行时，使隐私保护成为推理流程的内在属性而非模型导出后的附加步骤。

具体而言，协变处理覆盖现代 LLM 的关键组件。不仅处理线性投影与嵌入/输出头，还对 RMSNorm 与 RoPE 给出对应方案：对 RMSNorm 的可学习缩放参数 γ 同步施加 S 变换，并通过保守缩放区间（隐藏维度 $[\alpha, \beta] = [0.97, 1.03]$）控制数值误差；对 RoPE 采用逐头正交矩阵（保持 rotary pair 结构的二维块对角正交矩阵）使协变变换与位置旋转可交换，从而保持注意力分数与明文完全一致（$Q'_i K'^{\top}_i = Q_i K_i^{\top}$）。所有协变处理均通过算法 2 的词元级运行时等价性验证正确性。

在此基础上，本作品采用“构造 + 运行时验证”的双保险机制。局部协变关系给出理论条件，而算法 2 在模型导出后、部署前用验证样本集做逐词元比对与逐层相对误差校验，默认阈值 $\epsilon_{\text{max}} = 10^{-3}$，将算子融合、数值精度与具体硬件实现引入的偏差拦截在发布前，防止“数学上成立但实现中出错”的典型隐患。协变混淆还被接入边云推理运行时：边端在预填充前完成词元置换 $x' = \pi(x)$，云端加载混淆检查点在混淆词元空间上完成解码，边端聚合器用 π^{-1} 恢复输出；恢复密钥始终不离开边端，云端在整个推理过程中仅观察混淆词元，且边云协同本身可让边端承担部分注意力计算，进一步减少云端可见的中间激活范围。

在 1100 条提示、52575 个对齐词元对上、多组 L1/L2 安全评估实验中，该方案在唯密文威胁模型下取得混淆词元直读 0.00%、8 类敏感标识符零泄漏、频率分析 top-1 复原率不超过 1.6%、词元表面长度 Pearson 相关 0.083 的结果；同时稳态解码吞吐（121.68 词元/s）与明文切分基线（121.89 词元/s）基本持平，在实验范围内未观察到推理精度损失与明显性能退化。

4.3 统一调度接入与国产化平台适配

针对“安全模块与调度模块在实现中相互割裂、部署阶段易被绕过”的常见问题，本作品在系统层实现了“同一份层级切分策略同时驱动边云切分与混淆推理模块选择”的统一接入机制，并完成在国产 AI 加速平台上的端到端适配。

统一接入的核心在于将资源调度结果与隐私保护执行路径耦合到同一条可追踪的运行链路。调度后端生成策略 $\mathcal{P}$ 后，边端与云端运行时通过统一接口接收同一份策略描述；运行时内的推理模块工厂（算法 3）依据模型类型、运行角色与混淆材料环境，共同决定加载明文推理模块或混淆推理模块。这种设计降低了安全模块在配置失误、手工部署或模型重导出时被遗漏或绕过的概率。为防止系统在用户误配置情况下悄悄退化为不完整的安全路径，推理模块工厂在边端创建混淆预填充模块前强制校验客户端密钥是否配置：当服务端混淆检查点已配置而客户端密钥缺失时，工厂直

接拒绝创建，避免“云端看到明文却误以为处于混淆模式”的典型漏洞。

在硬件层面，平台不仅在 NVIDIA GPU 上完成部署，还将边云协同运行时与协变混淆链路迁移至华为昇腾 910B4-1（基于 CANN、MindIE、torch_npu），统一推理入口、协调聚合层、预填充节点与解码节点在国产 NPU 上保持与通用 GPU 一致的执行逻辑，500 条请求全部成功，P95 延迟 0.75 s。平台同时部署覆盖边端 GPU、云端 GPU 与昇腾 NPU 的基于 Grafana 的资源监控面板，从会话初始化到推理完成全程留日志，每个环节均可经界面或日志回溯复核。

综上，本作品通过算子层的细粒度切分与显存硬约束、协议层面向现代 LLM 组件的协变处理与运行时验证、系统层的统一接入校验与国产化适配三项递进创新，在效率、云端可见数据范围控制与部署可验证性之间形成完整方案，为隐私敏感场景下的边云协同大模型推理提供了可量化、可复核、可扩展的系统方案。

第五章 总结

PrivLLM 针对大语言模型在边云协同场景中“算力不足、明文直接进入云端不安全、现有安全方案难落地”三重瓶颈，提出了一套将资源感知细粒度切分、基于协变混淆的隐私保护推理与统一调度接入整合于同一闭环的工程方案。本文对平台设计、关键技术与实测结果进行了系统阐述，现总结如下。

第一章将问题归纳为三大挑战：边端算力受限与云端隐私风险之间的矛盾，密码学安全方案高开销与轻量扰动安全性不足之间的两难，以及切分调度、隐私保护与国产化适配缺少统一方案、安全机制易被绕过。第二章围绕这些挑战展开方案设计。为平衡边端算力约束与云端隐私暴露风险，提出了资源感知细粒度切分机制，将切分粒度细化至层内注意力头与 FFN，并把显存硬上限显式纳入策略公式，对应算法 1。为实现低开销的云端不可见推理，设计了协变混淆隐私推理链路，通过词表置换与协同可逆参数变换，并针对 RMSNorm 与 RoPE 进行协变处理，由算法 2 完成运行时等价性验证。为支撑完整系统运行，构建了统一调度接入机制，由同一份策略同时驱动切分加载与混淆推理模块选择，并在边端进行强密钥校验以防止服务退化，对应算法 3；该机制还与昇腾 910B4-1 完成国产化适配，将切分、隐私保护与国产算力整合为可运行系统。第三章与第四章从功能、性能、安全、创新四个维度对平台进行了系统评估。

实验结果总结。在真实边云硬件（云端 RTX 5090 + 昇腾 910B4-1、边端 RTX 4090、千兆以太网/gRPC）上使用 Llama-3.2-3B-Instruct 完成评估：

功能闭环。平台完成“前端登录 → 模型选择 → 切分策略生成 → 混淆推理 → 双栏结果展示 → 监控复核”的端到端流程，所有关键页面均保留截图证据。

推理性能。 900 条请求压测下，协变混淆链路取得端到端延迟 5.437 s、首词元延迟 4.910 s、**解码吞吐 121.68 词元/s**；与明文切分基线 121.89 词元/s 基本持平，相对差异约 0.17%，落在测量噪声范围内；与单机 134.05 词元/s 相比性能损耗主要来自边云网络预填充，而非混淆计算；10–57 Mbit/s 带宽范围内解码吞吐稳定在 121–122 词元/s，协变混淆不引入传输膨胀。

安全评估。基于 1100 条提示，覆盖 6 类场景，**52575 个对齐明文–混淆词元对**、多组 L1/L2 安全评估实验，在唯密文威胁模型下：混淆词元直读严格相等率 0.00%、8 类共 240 句敏感标识符零泄漏、频率分析单词元 top-1 复原率不超过 1.6%、词元表面长度 Pearson 相关 0.083；元数据侧信道分类准确率 26.4%–30.0%，仅略高于多数类基线 21.8%，属低强度，时延侧信道 65.1% 可由填充与速率归一化缓解。

国产化适配。在昇腾 910B4-1 上完成 500 条请求压测且全部成功，P95 延迟 0.75 s，

总吞吐 56.42 词元/s，验证了平台在通用 GPU 与国产 NPU 双平台的兼容能力。

综合上述结果，PrivLLM 在实验范围内实现了“接近明文切分的推理效率、可量化的云端可见数据范围控制、可复核可监控的运行系统”三个目标。

当前局限。本作品仍存在若干局限。当前实测模型以 Llama-3.2-3B 为主，更大规模模型，如 7B 及以上，以及 MoE、多模态等复杂架构尚未完成系统评估。元数据侧信道问题也需进一步关注：时延侧信道分类准确率达 65.1%，多请求关联的同类/跨类 Jaccard 比值约为 2×，虽不足以还原内容，但可能被用于粗粒度分类。

协变混淆本质上是对云端可见数据范围的可控缩减，并非密码学意义上可证明安全的加密方案，其安全性依赖于客户端密钥保密，无法抵御客户端侧密钥窃取等超出威胁模型的更强攻击者。此外，在网络条件较差时性能会退化：10 Mbit/s 以下带宽下 120 次请求中 110 次成功，窄带链路仍需进一步优化。昇腾 910B4-1 当前吞吐为 56.42 词元/s，与高端 GPU 相比仍有差距，主要受 CANN/torch_npu 算子优化程度制约，后续可通过图模式编译与算子融合进一步提升。

未来工作。基于上述局限，后续工作将从模型覆盖、任务扩展、侧信道抑制、通信优化与国产算力适配五个方面展开。在模型覆盖上，将支持更大规模 decoder-only 模型以及 MoE、多模态、encoder-decoder 等更复杂架构，提升平台在不同任务场景下的通用性；在任务形态上，逐步从推理向密态微调、密态训练迁移，推动大模型在隐私场景下的全生命周期部署。

在安全性上，将进一步抑制元数据侧信道：在协调层引入固定窗口时延填充、提示长度填充以及按会话派生的盐值，将元数据侧信道分类准确率压低至随机基线水平；同时从协议压缩、流水线并行与 KV 缓存复用等方向压缩边云通信开销，提升跨地域、窄带与多组织部署环境下的实用性。

在国产算力适配上，将持续优化昇腾等自主可控平台的算子栈与运行时，通过图模式编译与算子融合进一步提升推理吞吐与算子兼容性。

参考文献

[1] Stanford Institute for Human-Centered Artificial Intelligence. Artificial Intelligence Index Report 2025[R]. Stanford: Stanford Institute for Human-Centered Artificial Intelligence, 2025 [2026-07-05]. https://hai.stanford.edu/assets/files/hai_ai_index_report_2025.pdf.

[2] KNIGHT W. A Database Exposing DeepSeek Users' Chat Prompts and Internal Data Was Left Open[EB/OL]. 2025 [2026-07-04]. https://www.wired.com/story/exposed-deepseek-database-revealed-chat-prompts-and-internal-data/.

[3] National Institute of Standards and Technology. Artificial Intelligence Risk Management Framework (AI RMF 1.0) Generative Artificial Intelligence Profile[R]. NIST AI 600-1. Gaithersburg: National Institute of Standards and Technology, 2024. DOI: 10.6028/NIST.AI.600-1.

[4] OWASP Foundation. OWASP Top 10 for LLM Applications 2025[EB/OL]. 2025 [2026-07-04]. https://genai.owasp.org/llm-top-10/.

[5] OWASP Foundation. LLM02:2025 Sensitive Information Disclosure[EB/OL]. 2025 [2026-07-04]. https://genai.owasp.org/llmrisk/llm022025-sensitive-information-disclosure/.

[6] OWASP Foundation. LLM08:2025 Vector and Embedding Weaknesses[EB/OL]. 2025 [2026-07-04]. https://genai.owasp.org/llmrisk/llm082025-vector-and-embedding-weaknesses/.

[7] LUO Z, SHAO S, ZHANG S, et al. Shadow in the Cache: Unveiling and Mitigating Privacy Risks of KV-cache in LLM Inference[C]//Proceedings 2026 Network and Distributed System Security Symposium. The Internet Society, 2026. DOI: 10.14722/ndss.2026.240258.

[8] KANG Y, HAUSWALD J, GAO C, et al. Neurosurgeon: Collaborative Intelligence Between the Cloud and Mobile Edge[C]//Proceedings of the Twenty-Second International Conference on Architectural Support for Programming Languages and Operating Systems. New York: ACM, 2017: 615-629. DOI: 10.1145/3037697.3037698.

[9] JIN H, WU Y. CE-CoLLM: Efficient and Adaptive Large Language Models Through Cloud-Edge Collaboration[C]//2025 IEEE International Conference on Web Services. Piscataway: IEEE, 2025: 316-323. DOI: 10.1109/ICWS67624.2025.00046.

[10] HAO Z, JIANG H, JIANG S, et al. Hybrid SLM and LLM for Edge-Cloud Collaborative Inference[C]//Proceedings of the Workshop on Edge and Mobile Foundation Models. New York: ACM, 2024: 36-41. DOI: 10.1145/3662006.3662067.

[11] STAAB R, VERO M, BALUNOVIĆ M, et al. Beyond Memorization: Violating Privacy via Inference with Large Language Models[C]//The Twelfth International Conference on Learning Representations. OpenReview.net, 2024. DOI: 10.48550/arXiv.2310.07298.

[12] MORRIS J X, KULESHOV V, SHMATIKOV V, et al. Text Embeddings Reveal (Almost) as Much as Text[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2023: 12448-12460. DOI: 10.18653/v1/2023.emnlp-main.765.

[13] LIN Y, ZHANG Q, CAI Q, et al. An Inversion Attack Against Obfuscated Embedding Matrix in Language Model Inference[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2024: 2100-2104. DOI: 10.18653/v1/2024.emnlp-main.126.

[14] THOMAS R K, ZAHRAN L, CHOI E, et al. Hidden No More: Attacking and Defending Private Third-Party LLM Inference[C]//Proceedings of the 42nd International Conference on Machine Learning: vol. 267. Cambridge: PMLR, 2025: 59434-59469. https://proceedings.mlr.press/v267/thomas25b.html.

[15] DONG T, MENG Y, LI S, et al. Depth Gives a False Sense of Privacy: LLM Internal States Inversion[C]//34th USENIX Security Symposium (USENIX Security 25). Berkeley: USENIX Association, 2025. DOI: 10.48550/arXiv.2507.16372.

[16] MOHASSEL P, RINDAL P. ABY^3: A Mixed Protocol Framework for Machine Learning[C]//Proceedings of the 2018 ACM SIGSAC Conference on Computer and Communications Security. New York: ACM, 2018: 35-52. DOI: 10.1145/3243734.3243760.

[17] KELLER M. MP-SPDZ: A Versatile Framework for Multi-Party Computation[C]//Proceedings of the 2020 ACM SIGSAC Conference on Computer and Communications Security. New York: ACM, 2020: 1575-1590. DOI: 10.1145/3372297.3417872.

[18] KNOTT B, VENKATARAMAN S, HANNUN A, et al. CrypTen: Secure Multi-Party Computation Meets Machine Learning[C]//Advances in Neural Information Processing Systems 34. Red Hook: Curran Associates, Inc., 2021: 4961-4973. DOI: 10.48550/arXiv.2109.00984.

[19] HAO M, LI H, CHEN H, et al. Iron: Private Inference on Transformers[C]//Advances in Neural Information Processing Systems 35. Red Hook: Curran Associates, Inc., 2022: 15718-15731. DOI: 10.52202/068431-1143.

[20] LI D, SHAO R, WANG H, et al. MPCFormer: Fast, Performant and Private Transformer Inference with MPC[C]//The Eleventh International Conference on Learning Representations. OpenReview.net, 2023. DOI: 10.48550/arXiv.2211.01452.

[21] HOU X, LIU J, LI J, et al. CipherGPT: Secure Two-Party GPT Inference[J]. IEEE Transactions on Dependable and Secure Computing, 2026, 23(6): 6748-6762. DOI: 10.1109/TDSC.2026.3667722.

[22] LU W J, HUANG Z, GU Z, et al. BumbleBee: Secure Two-party Inference Framework for Large Transformers[C]//Proceedings 2025 Network and Distributed System Security Symposium. The Internet Society, 2025. DOI: 10.14722/ndss.2025.230057.

[23] PANG Q, ZHU J, MÖLLERING H, et al. BOLT: Privacy-Preserving, Accurate and Efficient Inference for Transformers[C]//2024 IEEE Symposium on Security and Privacy. Piscataway: IEEE, 2024: 4753-4771. DOI: 10.1109/SP54263.2024.00130.

[24] DONG Y, LU W J, ZHENG Y, et al. PUMA: Secure Inference of LLaMA-7B in Five Minutes[J]. Security and Safety, 2025, 4: 2025014. DOI: 10.1051/sands/2025014.

[25] DING Y, GUO H, GUAN Y, et al. East: Efficient and Accurate Secure Inference Framework for Transformer[J]. IEEE Transactions on Services Computing, 2025, 18(5): 2038-2046. DOI: 10.1109/TSC.2025.3577491.

[26] TAN Y, TAN C, MI Z, et al. PipeLLM: Fast and Confidential Large Language Model Services with Speculative Pipelined Encryption[C]//Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and

Operating Systems. New York: ACM, 2025: 843-857. DOI: 10.1145/3669940.3707224.

[27] HUANG Y, SONG Z, CHEN D, et al. TextHide: Tackling Data Privacy in Language Understanding Tasks[C]//Findings of the Association for Computational Linguistics: EMNLP 2020. Stroudsburg: Association for Computational Linguistics, 2020: 1368-1382. DOI: 10.18653/v1/2020.findings-emnlp.123.

[28] DU M, YUE X, CHOW S S M, et al. DP-Forward: Fine-tuning and Inference on Language Models with Differential Privacy in Forward Pass[C]//Proceedings of the 2023 ACM SIGSAC Conference on Computer and Communications Security. New York: ACM, 2023: 2665-2679. DOI: 10.1145/3576915.3616592.

[29] ZHANG J, YANG X, HE L, et al. Secure Transformer Inference Made Non-interactive[C]//Proceedings 2025 Network and Distributed System Security Symposium. The Internet Society, 2025. DOI: 10.14722/ndss.2025.230868.

[30] LIN Y, ZHANG Q, RUAN W, et al. Towards Privacy-Preserving LLM Inference via Covariant Obfuscation[EB/OL]. 2026. DOI: 10.48550/arXiv.2603.01499.

[31] Huawei Ascend. MindIE Ascend Community[EB/OL]. 2026 [2026-07-04]. https://www.hiascend.com/en/developer/software/mindie.

[32] Huawei Ascend. Model Inference on Ascend[EB/OL]. 2026 [2026-07-04]. https://www.hiascend.com/en/developer/inference.

[33] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems 30. Red Hook: Curran Associates, Inc., 2017: 5998-6008. DOI: 10.48550/arXiv.1706.03762.

[34] ZHANG B, SENNRICH R. Root Mean Square Layer Normalization[C]//Advances in Neural Information Processing Systems 32. Red Hook: Curran Associates, Inc., 2019: 12360-12371. DOI: 10.48550/arXiv.1910.07467.

[35] SU J, AHMED M, LU Y, et al. RoFormer: Enhanced Transformer with Rotary Position Embedding[J]. Neurocomputing, 2024, 568: 127063. DOI: 10.1016/j.neucom.2023.127063.

[36] LI E, ZENG L, ZHOU Z, et al. Edge AI: On-Demand Accelerating Deep Neural Network Inference via Edge Computing[J]. IEEE Transactions on Wireless Communications, 2020, 19(1): 447-457. DOI: 10.1109/TWC.2019.2946140.

[37] LIANG H, SANG Q, HU C, et al. DNN Surgery: Accelerating DNN Inference on the Edge Through Layer Partitioning[J]. IEEE Transactions on Cloud Computing, 2023, 11(3): 3111-3125. DOI: 10.1109/TCC.2023.3258982.

[38] TULI S, CASALE G, JENNINGS N R. SplitPlace: AI Augmented Splitting and Placement of Large-Scale Neural Networks in Mobile Edge Environments[J]. IEEE Transactions on Mobile Computing, 2023, 22(9): 5539-5554. DOI: 10.1109/TMC.2022.3177569.

[39] AINSLIE J, LEE-THORP J, de JONG M, et al. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2023: 4895-4901. DOI: 10.18653/v1/2023.emnlp-main.298.